HIỆU SUẤT SO VỚI GIÁ

Giá trị API của lượng dùng trong gói, chia cho phí subscription

Báo cáo thực hành cho Apero. Giá API kiểm tra 29/10/2026. Phép đo lấy từ tháng 9/2026.

Thông tin	Tóm tắt
Câu hỏi	Một gói subscription mua được lượng dùng model trị giá bao nhiêu đô la API, và hệ số đó so với phí là bao nhiêu.
Công thức	Hiệu suất = giá trị API của phần dùng được / phí gói. Trên 1: phần quy ra API lớn hơn phí. Bằng 1: phí mua đúng số đô la API đó.
Hai khoản	Credit ghi trên giá (Copilot, credit API của Claude Max). Và giá trị API của hạn mức trong app, đo từ log. Hai khoản đứng riêng, không cộng vào một hệ số.
Kết luận nhanh	Credit Copilot: Pro 1,50×, Pro+ 1,79×, Max 2,00×. Credit Claude Max đúng 1,00×. Log Codex tháng 9–10: Plus khoảng 13,40× nếu dùng hết 4 tuần; Pro $100 từ 7,00× đến khoảng 16× tùy bài đo.

Mục 1: cách tính. Mục 2: đơn giá API để quy đổi. Mục 3: hiệu suất credit. Mục 4: hiệu suất hạn mức đã đo. Mục 5: cách chọn gói. Mục 6: nguồn.

1. Cách tính hiệu suất của gói

Phí gói mua quyền dùng model trong ứng dụng, kèm hạn mức. Hiệu suất ở đây là số đô la API tương đương của phần dùng đó, chia cho phí. Đây là thước đo tiền, tách khỏi điểm benchmark.

Hạng mục	Cách làm
Tử số	Lượng token đã dùng hoặc được cấp, nhân đơn giá API của đúng model, đúng loại token (input mới, cache read, output).
Mẫu số	Phí subscription của tháng đó. Giá năm được quy về tháng khi nguồn đã quy.
Credit chính thức	Copilot: 1 AI credit = $0,01, và credit bị trừ theo giá token của model. Claude Max: credit API ghi bằng đô la trên claude.com/pricing.
Hạn mức app	Nhà cung cấp không công bố số token. Hệ số chỉ có khi có log đã định giá. Một tuần Codex nhân 4 là giả định của báo cáo này khi nguồn chỉ công bố số tuần.
Đơn giá	Mức Standard, input mới, chưa thuế. Cache, batch, fast mode và context dài làm cùng một log ra số đô la khác.

Cùng một hạn mức gói đổi ra số đô la rất khác nhau theo model. Ở kịch bản 10 triệu input và 2 triệu output, Luna và Haiku dưới 100.000 token là $2,00, Sol và Sonnet 5.5 là $40,00, Astra và Fable 5.1 là $200,00. Vì vậy một hệ số đo trên Sonnet không mang sang Fable, và một hệ số đo trên Codex không mang sang chat thường.

2. Đơn giá API dùng để quy đổi

USD / 1 triệu token, Standard, input mới. OpenAI ngày 29/10/2026. Claude rate card 22/10/2026. Gemini cập nhật 28/10/2026. DeepSeek docs 19/10/2026.

Model trong phép quy đổi	Input / 1M	Output / 1M	Ghi chú khi đổi log ra đô la
GPT-6 Luna	$0,10	$0,50	OpenAI Standard. Cache read $0,01.
GPT-6.1 Terra	$1,00	$5,00	OpenAI Standard. Cache read $0,05.
GPT-6.1 Sol	$2,00	$10,00	OpenAI Standard. Cache read $0,10.
GPT-6 Astra	$10,00	$50,00	OpenAI Standard. Cache read $1,00. Prompt trên 272.000 token input: cả request tính 2 lần input/cache và 1,5 lần output.
Claude Haiku 5.5, request đến 100.000 token	$0,10	$0,50	Claude API, Standard Global. Cache read $0,01. Ngưỡng tính trên từng request.
Claude Haiku 5.5, request trên 100.000 token	$0,50	$2,50	Cùng model, bậc cao hơn. Cache read $0,05. Cả tháng ở mức này khi mọi request đều vượt ngưỡng.
Claude Sonnet 5.5	$2,00	$10,00	Standard Global, mọi độ dài. Cache read $0,10. Cache write 5 phút $2,50.
Claude Opus 5.5	$4,00	$20,00	Standard Global. Cache read $0,20. Cache write 5 phút $5,00.
Claude Fable 5.1	$10,00	$50,00	Standard Global. Cache read $0,25. Fable 5 vẫn $10 / $50 nhưng cache read $1,00.
Gemini 3.8 Flash, đến 31/12/2026	$0,75	$3,75	gemini-3.8-flash, giá mở cửa. Từ 1/1/2027: $1,50 / $7,50. Output đã gồm thinking.
Gemini 4 Argon, đến 30/11/2026	$2,00	$10,00	gemini-4-argon, giá mở cửa. Từ 1/12/2026: $4,00 / $20,00. Cache $0,10 rồi $0,20. Chỉ implicit cache.
DeepSeek Flash, giờ cao điểm, cache miss	$0,30	$1,20	deepseek-flash, bản DeepSeek-V4.1-Flash-1017. Giờ thấp điểm bằng một nửa. Cache hit cao điểm $0,006, không dùng làm mốc.
DeepSeek V4-Pro, giờ cao điểm, cache miss	$1,32	$3,96	Bảng giá 19/10/2026 vẫn niêm yết id này. Thông báo 10/9 nói từ 14/9 id deepseek-v4-pro chuyển sang Flash đến khi có V4.1-Pro. Xác nhận id trước khi mua lượng lớn.

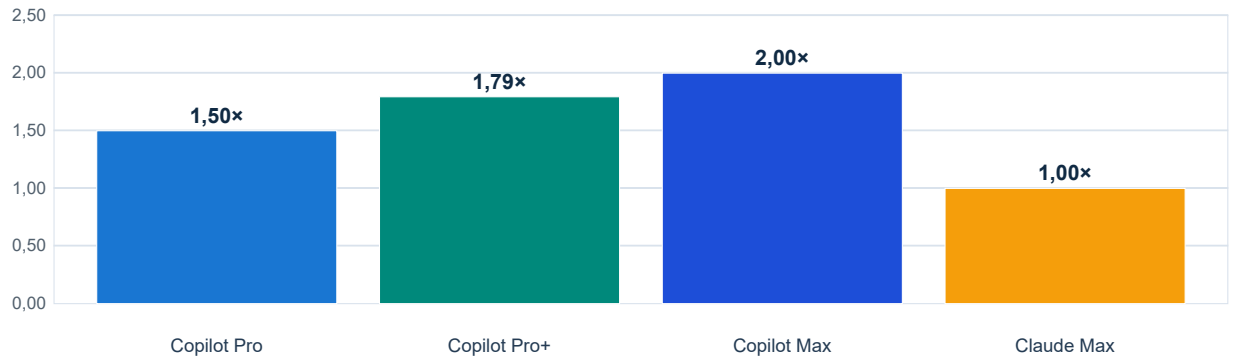
Argon lên $4 / $20 từ 1/12/2026. Gemini 3.8 Flash lên $1,50 / $7,50 từ 1/1/2027. DeepSeek giờ thấp điểm bằng một nửa giá cao điểm. Prompt GPT-6 Astra trên 272.000 token input tính 2 lần input và 1,5 lần output cho cả request. Haiku 5.5 nhảy bậc khi một request vượt 100.000 token.

3. Hiệu suất của credit ghi trên giá

Khoản này đọc được từ bảng giá, không cần log. Tử số là số đô la credit. Mẫu số là phí gói.

Gói	Phí	Credit quy ra API	Hiệu suất	Phạm vi của hệ số
Copilot Pro	$10,00	$15,00	1,50×	1.500 AI credit. Completion và NES không trừ credit, nên 1,50× là sàn của phần chat và agent.
Copilot Pro+	$39,00	$70,00	1,79×	7.000 credit. Cùng quy tắc trừ theo giá token của model.
Copilot Max	$100,00	$200,00	2,00×	20.000 credit. Auto giảm 10% giá model. Fusion giảm 30% đến 30/11/2026. Hai mức giảm làm cùng một credit đi được xa hơn, chưa cộng vào hệ số.
Copilot Business	$19,00	$19,00	1,00×	1.900 credit gộp mỗi ghế. Base credit bằng đúng phí ghế.
Copilot Enterprise	$39,00	$39,00	1,00×	3.900 credit gộp mỗi ghế.
Claude Pro	$20,00	$0,00	0,00×	Phí mua hạn mức Claude và Claude Code. Credit API bằng 0.
Claude Max 5x	$100,00	$100,00	1,00×	Credit API $100 mỗi kỳ, nếu liên kết Console. Đứng riêng với hạn mức app ở mục 4.
Claude Max 20x	$200,00	$200,00	1,00×	Credit API $200 mỗi kỳ. Credit không trả cho Claude Code chạy trực tiếp.

Hiệu suất credit = đô la credit / phí. Trục đến 2,50. Claude Max 5x và Max 20x cùng 1,00× nên biểu đồ chỉ vẽ một cột.



Perplexity Pro và Max không công bố số token để nhân với giá API của OpenAI, Anthropic hay Google. Gemini AI Plus, Pro và Ultra công bố bội số hạn mức (2×, 4×, 5×, 20× so với gói dưới), không công bố số token. Hai nhóm này chưa có hiệu suất API trong báo cáo. DeepSeek không có gói cá nhân.

4. Hiệu suất của hạn mức app, đo từ log

Đây là giá niêm yết để mua qua API đúng lượng token trong log hoặc trong phép thử dùng hết hạn mức. Không phải credit, không phải tiền hoàn, không phải hóa đơn thật.

Gói và phần được đo	Phí	Giá trị API và hiệu suất	Nguồn, từ tháng 9/2026
ChatGPT Plus, Codex	$20	Trung vị $67/tuần. Nhân 4 tuần: $268,00, hiệu suất 13,40×.	FinOps LLM, 27 cửa sổ từ tháng 8, cập nhật 10/10/2026. Bảy cửa sổ gần nhất $61–$81.
ChatGPT Plus, Codex	$20	Khoảng $66/tuần. Bài quy khoảng $285/tháng và khoảng 14×.	InventiveHQ, một cửa sổ 26/9, bài 4/10/2026. Số tháng là suy của bài đó.
ChatGPT Pro 100, Codex	$100	Trung vị $175/tuần, bằng 2,6× Plus. Nhân 4 tuần: $700,00, hiệu suất 7,00×.	FinOps LLM, 6 cửa sổ 27/9–8/10, bài 9/10/2026. Nhãn bán là 5× Plus.
ChatGPT Pro 100, Codex	$100	$330–$380/tuần. Bài quy $1.440–$1.640/tháng, khoảng 14–16×.	InventiveHQ, hai cửa sổ sạch, reset 30/9 và 3/10.
ChatGPT Pro 200, hạn mức mới	$200	$641–$670/tuần. Bài quy $2.800–$2.900/tháng, khoảng 14×.	InventiveHQ, hai cửa sổ reset 6/10 và 9/10.
ChatGPT Pro 200, hạn mức cũ	$200	Bài suy khoảng $1.300/tuần, khoảng 28×, bằng cách nhân đôi cửa sổ đã đo.	Suy đến hết 29/10/2026. Hạn mức cũ của cửa sổ 22–29/9 hết trong ngày này.
ChatGPT Pro 500	$500	Chưa có cửa sổ được định giá.	OpenAI không công bố bội số token. Ultrafast tiêu hạn mức 8 lần Standard.
Claude Max 20x, hết hạn mức	$200	Sonnet 5.5: $12.529 agent (62,6×), $7.009 chat (35,0×). Opus 5.5: $11.726 (58,6×), $9.200 (46,0×). Fable 5.1: khoảng $2.480 (12,4×).	SemiAnalysis, 5/10/2026. Chưa tính lại sau khi cache read Sonnet xuống $0,10 ngày 7/10. Fable dùng tối đa 50% hạn mức tuần.

Cách đọc hai nguồn Codex

FinOps và InventiveHQ cùng đo Codex, cùng lúc, ra hai mức cho Pro $100: 7,00× theo trung vị FinOps sau khi nhân 4 tuần, và khoảng 14–16× theo InventiveHQ. Báo cáo giữ cả hai. Plus nằm sát nhau, khoảng 13× đến 14×. Trên mỗi đô la phí, Plus cao hơn Pro $100 trong bài FinOps: họ đo Pro $100 bằng 2,6 lần hạn mức Plus trong khi phí gấp 5. InventiveHQ thấy các gói Pro gần cùng một hệ số khoảng 14×.

Credit API của Claude Max (mục 3, đúng 1,00×) và cột SemiAnalysis (mục 4) là hai khoản. Cộng chúng thành một hệ số sẽ đếm trùng. Chi tiết log Claude tháng 10 nằm ở báo cáo «3.So sánh Claude Pro Max Enterprise và API - 10.2026». Báo cáo này không gộp các log đó thành một số.

5. Chọn gói theo hiệu suất

Nhu cầu	Điểm vào	Vì sao, theo hệ số
Cần hệ số đọc được từ giá	Copilot Pro hoặc Max	Pro 1,50× trên credit, Max 2,00×. Completion không nằm trong tử số.
Code nhiều bằng Codex	Plus nếu chưa chạm trần tuần	Log tháng 9–10 cho Plus khoảng 13,40× đến 14× khi dùng hết tuần. Pro $100 mua thêm lượng, hệ số mỗi đô la tùy bài đo.
Code nhiều bằng Claude	Max khi đã chạm trần Pro	Credit API đúng bằng phí. Phần app, nếu dùng hết hạn mức tháng 10, từ khoảng 12× với Fable đến vài chục lần với Sonnet và Opus.
Chat, file, nghiên cứu	Giữ một gói $20	Chưa có log chat thường được định giá theo API trong tháng 9–10. Perplexity và Gemini chưa ra được hệ số token.
Sản phẩm tự gọi API	Trả theo token	Gói subscription không cấp một số token cố định cho sản phẩm. Credit Claude Max chỉ bù API khi đủ điều kiện Console.

Điểm vào cho Apero: Copilot Pro cho người code khi cần một hệ số credit chắc; Claude Pro hoặc ChatGPT Plus cho việc viết và đọc; chỉ lên Max hoặc Pro 100/200/500 khi log của chính nhóm, định giá theo bảng mục 2, đã vượt phí gói.

6. Nguồn và giới hạn

Đơn giá kiểm tra 29/10/2026. Hệ số log giữ nguyên ngày đo của từng bài.

Nguồn	Liên kết
OpenAI, đơn giá API	https://developers.openai.com/api/docs/pricing
ChatGPT Pro 100 / 200 / 500	https://help.openai.com/en/articles/9793128-about-chatgpt-pro-tiers
FinOps LLM, Codex Plus và Pro $100	https://finopsllm.com/research/chatgpt-pro-100-real-codex-multiplier
InventiveHQ, đo Codex trên Plus và Pro	https://inventivehq.com/blog/codex-subscription-usage-measured
Claude, giá gói và credit API	https://claude.com/pricing
Claude rate card 22/10/2026	https://assets.claude.com/5633dc848caa431115468f31c7085d695bbfb9cc.pdf
SemiAnalysis, Max 20x ngày 5/10/2026	Dẫn lại từ báo cáo Claude cùng thư mục. Bài gốc có thể yêu cầu tài khoản.
Gemini API	https://ai.google.dev/gemini-api/docs/pricing
Gemini, gói cá nhân	https://gemini.google/subscriptions/
DeepSeek, 19/10/2026	https://api-docs.deepseek.com/quick_start/pricing
GitHub Copilot, credit	https://docs.github.com/copilot/concepts/billing/usage-based-billing-for-individuals
GitHub Copilot, trang gói	https://github.com/features/copilot/plans

Giới hạn

Nhân 4 là giả định của báo cáo khi nguồn chỉ có số tuần. Một tháng lịch có thể hơn hoặc kém 4 cửa sổ. Hai bài Codex không thống nhất ở Pro $100. SemiAnalysis là phép dùng hết hạn mức ngày 5/10, trước lần giảm giá cache read của Sonnet. ChatGPT Go $8 và Plus $20 trên trang chat không hiện trong HTML giá chính thức đã tải; phí Plus $20 trong bảng log là mức các bài đo dùng. Perplexity Max $200 lấy từ bài help sửa 14/9/2026. Pro $20 là đối chiếu 23–28/10/2026.

Hiệu suất một gói là giá trị API của phần dùng được chia cho phí. Credit Copilot nằm từ 1,00× đến 2,00×. Credit Claude Max đúng 1,00×, và hạn mức app là khoản thứ hai. Log Codex tháng 9–10 đặt Plus quanh 13× đến 14× khi dùng hết tuần. Cùng một phí mua hệ số khác nhau theo model và theo cách đo.

Tài liệu tham khảo nội bộ Apero. Định giá lại bằng log của nhóm và bảng đơn giá mục 2 trước khi nâng gói.