HIỆU SUẤT SO VỚI GIÁ

API theo token hay thuê bao tháng: phương án nào kinh tế hơn?

Báo cáo thực hành cho Apero. Giá kiểm tra 29/10/2026, nguồn từ tháng 9/2026.

Thông tin	Tóm tắt
Mục tiêu	Cùng một lượng token, so chi phí API với giá thuê bao.
Phạm vi	OpenAI GPT-6, Claude Sonnet 5.5 / Opus 5.5 / Haiku 5.5 / Fable 5.1, Gemini 4 Argon, Gemini 3.8 Flash, DeepSeek V4, và các gói ChatGPT, Claude, Gemini, Perplexity, Copilot.
Kịch bản chuẩn	10 triệu token input + 2 triệu token output mỗi tháng. Thêm mức nhẹ (1M + 0,2M) và nặng (50M + 10M), cùng tỷ lệ 5:1.
Kết luận nhanh	Ở mức chuẩn, Luna khoảng $2, Terra đúng $20, Sol / Sonnet / Argon ưu đãi $40, Opus $80, Astra và Fable 5.1 $200. Gói $20 chỉ rẻ hơn khi gói đó mở đúng model và hạn mức cho phép lượng token ấy.

Thước đo của báo cáo này là tiền cho cùng một lượng sử dụng. Đây là phép so kinh tế, tách khỏi bảng xếp hạng benchmark. API tính theo token. Thuê bao có giao diện, công cụ và hạn mức riêng, và không cam kết một số token cố định.

Mục 1: cách tính. Mục 2: giá API. Mục 3: hòa vốn. Mục 4: giá thuê bao. Mục 5: khuyến nghị. Mục 6: nguồn.

1. Cách tính API so với thuê bao

Hai phương án được đặt lên cùng một lượng token input và output trong một tháng. Số tiền API được so với phí thuê bao. Chất lượng model nằm ngoài phép tính này.

Hạng mục	Giả định chuẩn	Cách tính
Input	10 triệu token/tháng	Số triệu token input × giá input
Output	2 triệu token/tháng	Số triệu token output × giá output
Tỷ lệ	5 input : 1 output	Mức nhẹ và nặng giữ cùng tỷ lệ
Baseline	Input mới, không cache	Không gồm batch, fast mode, context dài, web search
Thuê bao	Giá niêm yết	Chỉ so được khi gói mở đúng model và hạn mức chấp nhận lượng đó

Công thức

Chi phí API = (input, triệu token × giá input) + (output, triệu token × giá output).
Với tỷ lệ 5:1, mỗi 1 triệu token input kéo theo 0,2 triệu token output. Lượng input để chạm $20 = 20 / (giá input + 0,2 × giá output).

Những khoản nằm ngoài số headline

Cache read, batch (thường giảm 50% với các model này), fast mode và context dài làm hóa đơn lệch khỏi bảng. Với Claude và Gemini, token suy nghĩ nằm trong giá output: 2 triệu output của kịch bản là phần được tính tiền, gồm thinking nếu nhà cung cấp tính thinking như output. Web search, grounding và tool tính riêng. US-only inference của Claude nhân 1,1 lần giá input và output. Endpoint regional và FedRAMP của OpenAI cộng 10% với model ra từ 5/3/2026.

Ba kịch bản chỉ là mô hình. Token thật lấy từ log API.

2. Giá API đang niêm yết

USD cho 1 triệu token, mức Standard, chưa thuế. OpenAI: trang giá ngày 29/10/2026. Claude: rate card hiệu lực 22/10/2026. Gemini: trang giá cập nhật 28/10/2026. DeepSeek: docs 19/10/2026.

Model	Input / 1M	Output / 1M	Điều kiện của đơn giá
GPT-6 Luna	$0,10	$0,50	OpenAI Standard. Cache read $0,01.
GPT-6.1 Terra	$1,00	$5,00	OpenAI Standard. Cache read $0,05.
GPT-6.1 Sol	$2,00	$10,00	OpenAI Standard. Cache read $0,10.
GPT-6 Astra	$10,00	$50,00	OpenAI Standard. Cache read $1,00. Prompt trên 272.000 token input: cả request tính 2 lần input/cache và 1,5 lần output.
Claude Haiku 5.5, request đến 100.000 token	$0,10	$0,50	Claude API, Standard Global. Cache read $0,01. Ngưỡng tính trên từng request.
Claude Haiku 5.5, request trên 100.000 token	$0,50	$2,50	Cùng model, bậc cao hơn. Cache read $0,05. Cả tháng ở mức này khi mọi request đều vượt ngưỡng.
Claude Sonnet 5.5	$2,00	$10,00	Standard Global, mọi độ dài. Cache read $0,10. Cache write 5 phút $2,50.
Claude Opus 5.5	$4,00	$20,00	Standard Global. Cache read $0,20. Cache write 5 phút $5,00.
Claude Fable 5.1	$10,00	$50,00	Standard Global. Cache read $0,25. Fable 5 vẫn $10 / $50 nhưng cache read $1,00.
Gemini 3.8 Flash, đến 31/12/2026	$0,75	$3,75	gemini-3.8-flash, giá mở cửa. Từ 1/1/2027: $1,50 / $7,50. Output đã gồm thinking.
Gemini 4 Argon, đến 30/11/2026	$2,00	$10,00	gemini-4-argon, giá mở cửa. Từ 1/12/2026: $4,00 / $20,00. Cache $0,10 rồi $0,20. Chỉ implicit cache.
DeepSeek Flash, giờ cao điểm, cache miss	$0,30	$1,20	deepseek-flash, bản DeepSeek-V4.1-Flash-1017. Giờ thấp điểm bằng một nửa. Cache hit cao điểm $0,006, không dùng làm mốc.
DeepSeek V4-Pro, giờ cao điểm, cache miss	$1,32	$3,96	Bảng giá 19/10/2026 vẫn niêm yết id này. Thông báo 10/9 nói từ 14/9 id deepseek-v4-pro chuyển sang Flash đến khi có V4.1-Pro. Xác nhận id trước khi mua lượng lớn.

Mốc đổi giá và giờ thấp điểm

Mốc	Input / 1M	Output / 1M	Kịch bản chuẩn
Gemini 4 Argon từ 1/12/2026	$4,00	$20,00	$80,00
Gemini 3.8 Flash từ 1/1/2027	$1,50	$7,50	$30,00
DeepSeek Flash, giờ thấp điểm, cache miss	$0,15	$0,60	$2,70
DeepSeek V4-Pro, giờ thấp điểm, cache miss	$0,66	$1,98	$10,56

Giờ cao điểm DeepSeek, theo docs 19/10/2026: thứ Hai đến thứ Sáu, 01:00–04:00 và 06:00–10:00 UTC, trừ ngày lễ Trung Quốc. Giờ còn lại, cả ngày thứ Bảy, Chủ nhật và ngày lễ, tính một nửa. Search và Fetch $0,75 / 1.000 request thành công. Tool phía server qua DeepSeek Harness, Claude Code và Codex được miễn đến 00:00 giờ Bắc Kinh ngày 1/11/2026.

Haiku 5.5 đổi giá theo từng request. Tổng 10 triệu token trong tháng vẫn ở mức $0,10 / $0,50 nếu mọi request đứng dưới 100.000 token. Một request vượt ngưỡng thì request đó tính $0,50 / $2,50. Trang Gemini còn các thẻ giá khác (batch, context, model ảnh). Báo cáo chỉ lấy thẻ Standard của Argon và của Gemini 3.8 Flash.

Cache làm hóa đơn agent thấp hơn bảng

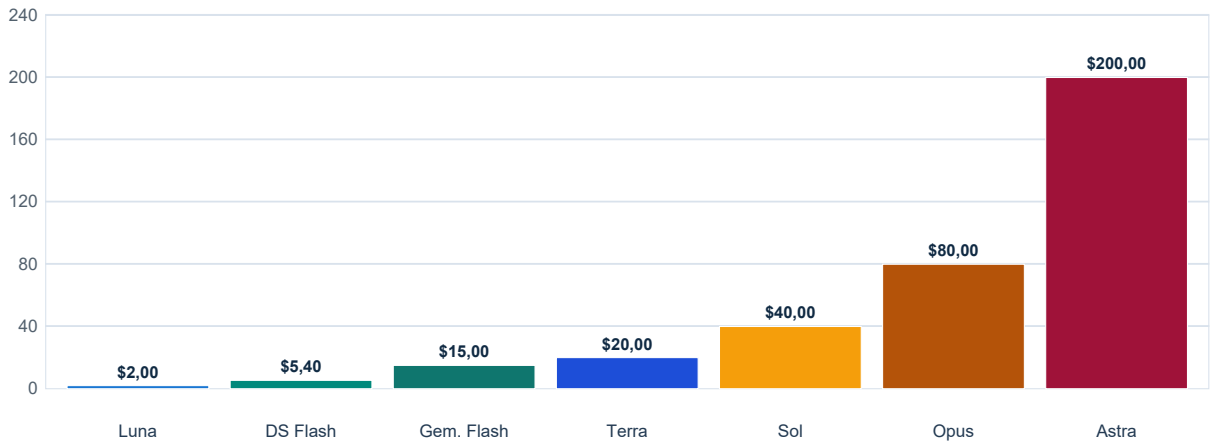
Phiên agent đọc lại prefix đã cache. Sonnet 5.5 cache read $0,10 so với input $2,00. Fable 5.1 cache read $0,25 so với input $10,00. Bảng headline là trường hợp input mới toàn bộ. Hóa đơn thật có thể thấp hơn nhiều khi phần lớn input là cache read. Báo cáo không giả định một tỷ lệ cache để tính lại cả bảng.

3. Hòa vốn với gói $20

Số tiền dưới đây là chi phí API của đúng kịch bản. Cột cuối là lượng token, theo tỷ lệ 5:1, để API chạm $20.

Model	Nhẹ	Chuẩn	Nặng	So với gói $20
GPT-6 Luna	$0,20	$2,00	$10,00	Cả ba mức đều dưới $20. Mốc $20: 100,00M input + 20,00M output.
GPT-6.1 Terra	$2,00	$20,00	$100,00	Đúng $20 ở mức chuẩn. Mốc $20: 10,00M input + 2,00M output.
GPT-6.1 Sol	$4,00	$40,00	$200,00	Vượt $20 sau mốc này. Mốc $20: 5,00M input + 1,00M output.
GPT-6 Astra	$20,00	$200,00	$1.000,00	Bằng $20 ngay ở mức nhẹ. Mốc $20: 1,00M input + 0,20M output.
Claude Haiku 5.5, request đến 100.000 token	$0,20	$2,00	$10,00	Cả ba mức đều dưới $20. Mốc $20: 100,00M input + 20,00M output.
Claude Haiku 5.5, request trên 100.000 token	$1,00	$10,00	$50,00	Nhẹ và chuẩn dưới $20; nặng vượt $20. Mốc $20: 20,00M input + 4,00M output.
Claude Sonnet 5.5	$4,00	$40,00	$200,00	Vượt $20 sau mốc này. Mốc $20: 5,00M input + 1,00M output.
Claude Opus 5.5	$8,00	$80,00	$400,00	Vượt $20 sau mốc này. Mốc $20: 2,50M input + 0,50M output.
Claude Fable 5.1	$20,00	$200,00	$1.000,00	Bằng $20 ngay ở mức nhẹ. Mốc $20: 1,00M input + 0,20M output.
Gemini 3.8 Flash, đến 31/12/2026	$1,50	$15,00	$75,00	Nhẹ và chuẩn dưới $20; nặng vượt $20. Mốc $20: 13,33M input + 2,67M output.
Gemini 4 Argon, đến 30/11/2026	$4,00	$40,00	$200,00	Vượt $20 sau mốc này. Mốc $20: 5,00M input + 1,00M output.
DeepSeek Flash, giờ cao điểm, cache miss	$0,54	$5,40	$27,00	Nhẹ và chuẩn dưới $20; nặng vượt $20. Mốc $20: 37,04M input + 7,41M output.
DeepSeek V4-Pro, giờ cao điểm, cache miss	$2,11	$21,12	$105,60	Vượt $20 sau mốc này. Mốc $20: 9,47M input + 1,89M output.

USD, kịch bản chuẩn, input mới không cache. Trục đến $240 để cột Astra $200 còn nằm trong hình. Sol đại diện cho Sonnet 5.5 và Argon ưu đãi (cùng $40). Astra đại diện cho Fable 5.1 (cùng $200).



Cách đọc

Terra chạm đúng $20,00 ở mức chuẩn, tức 10M input + 2M output. Luna, Haiku khi mọi request dưới 100.000 token, và DeepSeek Flash giờ cao điểm đều dưới $20 ở mức chuẩn ($2,00, $2,00, $5,40). DeepSeek Flash giờ cao điểm ở mức nặng là $27,00. Sol, Sonnet 5.5 và Argon ưu đãi vượt $20 sau 5,00M input + 1,00M output. Opus 5.5, và Argon từ 1/12/2026, vượt sau 2,50M input + 0,50M output. Astra và Fable 5.1 bằng $20 ngay ở mức nhẹ.

Phép so với $20 chỉ đúng khi gói $20 mở đúng model đó và hạn mức thật sự cho phép lượng token đó. Astra đầy đủ hơn ở ChatGPT Pro. Fable 5.1 nằm ở nhóm Max của Perplexity. Google AI Plus $4,99 có ghi Gemini 4 Argon, nhưng hạn mức là bội số của gói miễn phí.

4. Giá thuê bao để đối chiếu

Thuê bao không đổi ra một số token cố định. Cột giá dưới đây để biết gói nào đang mở model nào, rồi mới mang về bảng hòa vốn.

Gói	Giá	Model và hạn mức đã ghi	Nguồn
ChatGPT Go	$8/tháng	Số này không nằm trên HTML openai.com/chatgpt/pricing đã tải. Nhiều trang theo dõi giá, đối chiếu chatgpt.com ngày 17–28/10/2026, ghi mức này.	Đối chiếu
ChatGPT Plus	$20/tháng, trả theo tháng	Cùng nhóm trang theo dõi. Họ ghi model chat mặc định là GPT-6.1 Sol từ khoảng 7/10/2026, và Astra bị hạn chế trên Plus.	Đối chiếu
ChatGPT Pro 100	$100/tháng	Ultrafast không có trong gói.	Help Center, bài 9793128
ChatGPT Pro 200	$200/tháng	Đăng ký mới ngoài cửa sổ 22–29/9/2026 có hạn mức thấp hơn. Hạn mức cũ giữ đến hết 29/10/2026. Giá vẫn $200. Pro trả theo tháng.	Help Center, bài 9793128
ChatGPT Pro 500	$500/tháng	Có Ultrafast cho GPT-6 Astra và GPT-6.1 Sol. Hạn mức tiêu hao 8 lần Standard, sau đó credit 6 lần.	Help Center, bài 9793128
Claude Pro	$20/tháng, hoặc $17/tháng khi trả $200 trước một năm	Ít nhất 5 lần Free mỗi phiên. Hạn mức là phiên 5 giờ và hạn tuần.	claude.com/pricing, 29/10/2026
Claude Max	Từ $100/tháng, mức 5x và 20x so với Pro	Kèm credit API $100/tháng (Max 5x) hoặc $200/tháng (Max 20x). Credit không phải tiền mặt và không trả cho Claude Code dùng trực tiếp. Bảng model ghi Fable trên Max ở mức 50% hạn tuần.	claude.com/pricing
Claude Team	Standard $25/ghế/tháng hoặc $20 trả năm. Premium $125 hoặc $100 trả năm.	Premium bằng 5 lần ghế Standard. Pool credit API tối đa $500/tháng.	claude.com/pricing
Claude Enterprise	$20/ghế/tháng, trả năm, tối thiểu 20 ghế	Cộng usage theo giá API. Không có credit API sẵn.	claude.com/pricing
Google AI Plus	$4,99/tháng	2 lần free, có Gemini 4 Argon, 400 GB. Gói gồm lưu trữ.	gemini.google/subscriptions/
Google AI Pro	$19,99/tháng	4 lần free, 5 TB. Một trang Google One ghi năm $199,99. Giá trị nằm ở bộ lưu trữ và ứng dụng Google.	gemini.google/subscriptions/
Google AI Ultra	$99,99/tháng (5 lần Pro) và $199,99/tháng (20 lần Pro)	Trang Google One cũ vẫn ghi $249,99 và 30 TB. Báo cáo lấy số trên gemini.google/subscriptions/.	gemini.google/subscriptions/
Perplexity Pro	$20/tháng hoặc $200/năm	Trang help so sánh gói bị Cloudflare khi đọc trực tiếp, nên $20 là đối chiếu trang giá và bundle JS ngày 23–28/10/2026. Help model sửa 27/10/2026: GPT-6.1 Sol, Gemini 3.8 Flash, Sonnet 5.5, Kimi K3, GLM 5.3, Grok 4.7, Nemotron 3.5 Super VL.	Đối chiếu + help model
Perplexity Max	$200/tháng hoặc $2.000/năm	Thêm GPT-6 Astra, Gemini 4 Argon, Opus 5.5, Fable 5.1. Hạn mức là mức dùng trung bình theo tuần và tháng.	Help Max, sửa 14/9/2026
Perplexity Enterprise	Pro $40/ghế hoặc $400/năm. Max $325/ghế hoặc $3.250/năm.	Cùng cách chia model giữa Enterprise Pro và Enterprise Max.	Help, cập nhật 8/10/2026
GitHub Copilot Pro	$10/tháng, 1.500 AI credit	1.000 base + 500 flex. 1 credit = $0,01, tức khoảng $15 usage. Completion và NES không tốn credit.	docs.github.com và trang plans
Copilot Pro+	$39/tháng, 7.000 credit	3.900 + 3.100. Khoảng $70 usage.	Cùng nguồn
Copilot Max	$100/tháng, 20.000 credit	10.000 + 10.000. Khoảng $200 usage.	Cùng nguồn
Copilot Business / Enterprise	$19 và $39 mỗi ghế	1.900 và 3.900 credit gộp. Auto giảm 10%. Fusion giảm 30% đến 30/11/2026. Không đổi credit ra kịch bản 10M + 2M vì không có hạn token công khai.	Cùng nguồn
DeepSeek	Không có gói cá nhân chính thức	So bằng API ở mục 2.	Docs 19/10/2026

Câu hỏi gói Max của Claude có đáng tiền hơn API, kể cả credit $100–$200, nằm ở hai báo cáo cùng thư mục: «2.Claude - Quy đổi gói sang giá trị API» và «3.So sánh Claude Pro Max Enterprise và API - 10.2026». Báo cáo này không lặp lại phần đó.

5. Khuyến nghị theo nhu cầu

Nhu cầu	Lựa chọn đầu	Phương án khác	Lý do
Văn phòng đa năng	ChatGPT Plus hoặc Google AI Pro	Claude Pro	Plus hợp viết, file và workflow. AI Pro hợp khi đã nằm trong Gmail, Docs, Drive. Kiểm tra lại giá Plus vì HTML chính thức không hiện số.
Viết tài liệu dài	Claude Pro	ChatGPT Plus	Sonnet 5.5 ở mức chuẩn là $40 API. Pro $20 có lợi thế tiền nếu hạn mức chịu được lượng viết đó.
Nghiên cứu, cần nguồn	Perplexity Pro	ChatGPT Plus	Lấy giá Pro $20 theo đối chiếu 23–28/10/2026. Max $200 mới mở Astra, Argon, Opus 5.5 và Fable 5.1.
Lập trình trong IDE	Copilot Pro	Thêm một ghế Claude hoặc ChatGPT	Copilot tính bằng credit, không bằng kịch bản 10M + 2M. Model mạnh dùng cho phân tích kiến trúc nằm ở ghế chat.
Sản phẩm gọi API nhiều	Luna, Haiku, Gemini Flash hoặc DeepSeek Flash	Mua Pro hoặc Max khi chạm hạn ứng dụng	Ở mức chuẩn, nhóm này nằm dưới hoặc sát $20 API. Astra và Fable 5.1 đạt $200 ở cùng mức.
Nhóm nhỏ	1–2 ghế Pro để chuẩn hóa việc	Business khi cần quản trị và thanh toán	Nâng gói sau 30 ngày nếu nhật ký tác vụ chỉ ra giờ tiết kiệm lớn hơn phí.

Thử 30 ngày

Tuần 1: ghi 10 tác vụ thường làm và thời gian hiện tại.
Tuần 2: dùng cùng bộ prompt, đo thời gian, số lần sửa và chất lượng.
Tuần 3: ghi lúc bị chặn hạn, model thực sự mở được, và tính năng đã dùng.
Tuần 4: giữ gói có giờ tiết kiệm nhân giá trị giờ lớn hơn phí. Hủy gói trùng việc.

Điểm vào cho Apero: 1–2 tài khoản Claude Pro hoặc ChatGPT Plus để chuẩn hóa việc viết và đọc tài liệu; Copilot Pro cho người code; Perplexity Pro cho người cần nguồn. API trả theo token cho phần việc lặp lại, ưu tiên Luna, Haiku, Gemini 3.8 Flash và DeepSeek Flash. Chỉ lên Max hoặc Pro 100/200/500 khi hạn mức ứng dụng là chỗ thật sự.

6. Nguồn, giới hạn, checklist

Kiểm tra ngày 29/10/2026. Giá có thể đổi sau các mốc ghi trong bảng.

Nguồn	Liên kết
OpenAI API	https://developers.openai.com/api/docs/pricing
GPT-6 Astra, context trên 272K	https://platform.openai.com/docs/models/gpt-6-astra
ChatGPT Pro 100 / 200 / 500	https://help.openai.com/en/articles/9793128-about-chatgpt-pro-tiers
ChatGPT, trang giá (HTML không hiện số Plus/Go)	https://openai.com/chatgpt/pricing/
Claude, giá gói	https://claude.com/pricing
Claude rate card 22/10/2026	https://assets.claude.com/5633dc848caa431115468f31c7085d695bbfb9cc.pdf
Gemini API, cập nhật 28/10/2026	https://ai.google.dev/gemini-api/docs/pricing
Gemini, gói cá nhân	https://gemini.google/subscriptions/
DeepSeek, 19/10/2026	https://api-docs.deepseek.com/quick_start/pricing
DeepSeek, thông báo 10/9/2026 về id V4-Pro	https://api-docs.deepseek.com/news/news260910
Perplexity Max	https://www.perplexity.ai/help-center/en/articles/11680686-perplexity-max
Perplexity, model trong gói, sửa 27/10/2026	https://www.perplexity.ai/help-center/en/articles/10354919-what-advanced-ai-models-are-included-in-my-subscription
GitHub Copilot	https://github.com/features/copilot/plans
GitHub Copilot, tài liệu gói	https://docs.github.com/en/copilot/about-github-copilot/subscription-plans-for-github-copilot

Mốc cần xem lại

Argon hết giá mở cửa ngày 30/11/2026. Gemini 3.8 Flash hết giá mở cửa ngày 31/12/2026. Fusion của Copilot giảm 30% đến 30/11/2026. Tool phía server của DeepSeek bắt đầu tính sau 00:00 giờ Bắc Kinh ngày 1/11/2026. Hạn mức cũ của ChatGPT Pro 200 giữ đến hết 29/10/2026. GPT-5.6 Sol còn giá khuyến mãi ít nhất đến 21/11/2026; model này không nằm trong bộ so sánh.

Giới hạn

ChatGPT Go $8 và Plus $20 lấy từ nhiều trang theo dõi giá ngày 17–28/10/2026, vì HTML trang giá OpenAI không hiện con số. Perplexity Pro $20 lấy từ đối chiếu trang giá và bundle JS ngày 23–28/10/2026; trang help so sánh gói bị chặn khi đọc trực tiếp. Max $200 lấy từ bài help chính thức. Thuế, khuyến mãi theo nước và cửa hàng Apple hoặc Google Play có thể lệch giá web. Benchmark công khai không được dùng làm hiệu suất trong báo cáo này.

Checklist trước khi trả tiền

Gói có mở đúng model đang cần. Hạn mức tuần cao điểm có đủ. Công việc có dữ liệu nhạy cảm hay không. Đã có sẵn trong IDE hoặc bộ tài liệu đang dùng. Hủy được và biết ngày gia hạn. Với API, log có tách cache, batch và thinking.

Không có một gói rẻ nhất cho mọi việc. Ở mức chuẩn, model $2 / $10 đã thành $40 API, nên gói $20 có lợi thế tiền khi nó mở đúng model đó và hạn mức chịu được. Luna, Haiku dưới ngưỡng 100.000 token và DeepSeek Flash giờ cao điểm vẫn dưới $20 ở mức chuẩn. Astra và Fable 5.1 bằng $20 ngay từ mức nhẹ, và chúng nằm ở gói cao hơn gói $20.

Tài liệu tham khảo nội bộ Apero. Đối chiếu lại giá và điều khoản trên trang chính thức trước khi mua.