APERO / TÀI LIỆU ĐỐI CHIẾU ĐA HÃNG

So sánh các model AI phổ biến

Benchmark, giá API input/output và những điều kiện dễ làm lệch hóa đơn

Chốt dữ liệu: 28/10/2026 · 11 nhà cung cấp · 28 model · USD trên một triệu token (MTok)

Tài liệu chọn các model API text tổng quát ở 11 hãng. Benchmark tách riêng Arena Text, AA Index cùng 10 bài thành phần, và mốc VMLU tiếng Việt đời cũ; không trộn các thang điểm thành một thứ hạng. Biểu đồ chi phí dùng cùng một công thức. Giá là rate card API trực tiếp, không phải gói ChatGPT, Claude, Kimi Code hay token plan.

> Không có một model thắng mọi việc. Arena Text đo sở thích người dùng với câu hỏi mở; chi phí token không thay cho chất lượng. Dùng điểm để lập shortlist, rồi chạy thử bằng prompt tiếng Việt và công cụ thật của bạn. Arena Text leaderboard

ĐIỂM ARENA CAO NHẤT TRONG MẪU	CHI PHÍ MẪU THẤP NHẤT	NGƯỠNG GIÁ CẦN NHỚ
Gemini 4 Argon: 1517 ±7; Claude Opus 5.5 và Muse Wonder: 1509 ±7/±8. Ảnh chụp 22/10; mẫu top có 8,946,356 phiếu tổng.	Claude Haiku 5.5: $0.15; GPT-6 Luna: $0.15; Qwen3.8 Flash: $0.151 cho lượt chuẩn hóa bên dưới.	Haiku >100K prompt tăng 5x; Grok ≥200K tăng 2x; OpenAI >272K có hệ số long-context.

Phạm vi

OpenAI, Anthropic, Google Gemini, Meta, xAI, DeepSeek, Alibaba Qwen, Z.ai, Mistral, Moonshot Kimi và Xiaomi MiMo. Chỉ tính API văn bản tổng quát có giá input/output công khai; không gom API hình ảnh, âm thanh, embedding hay gói thuê bao vào cùng đơn vị.

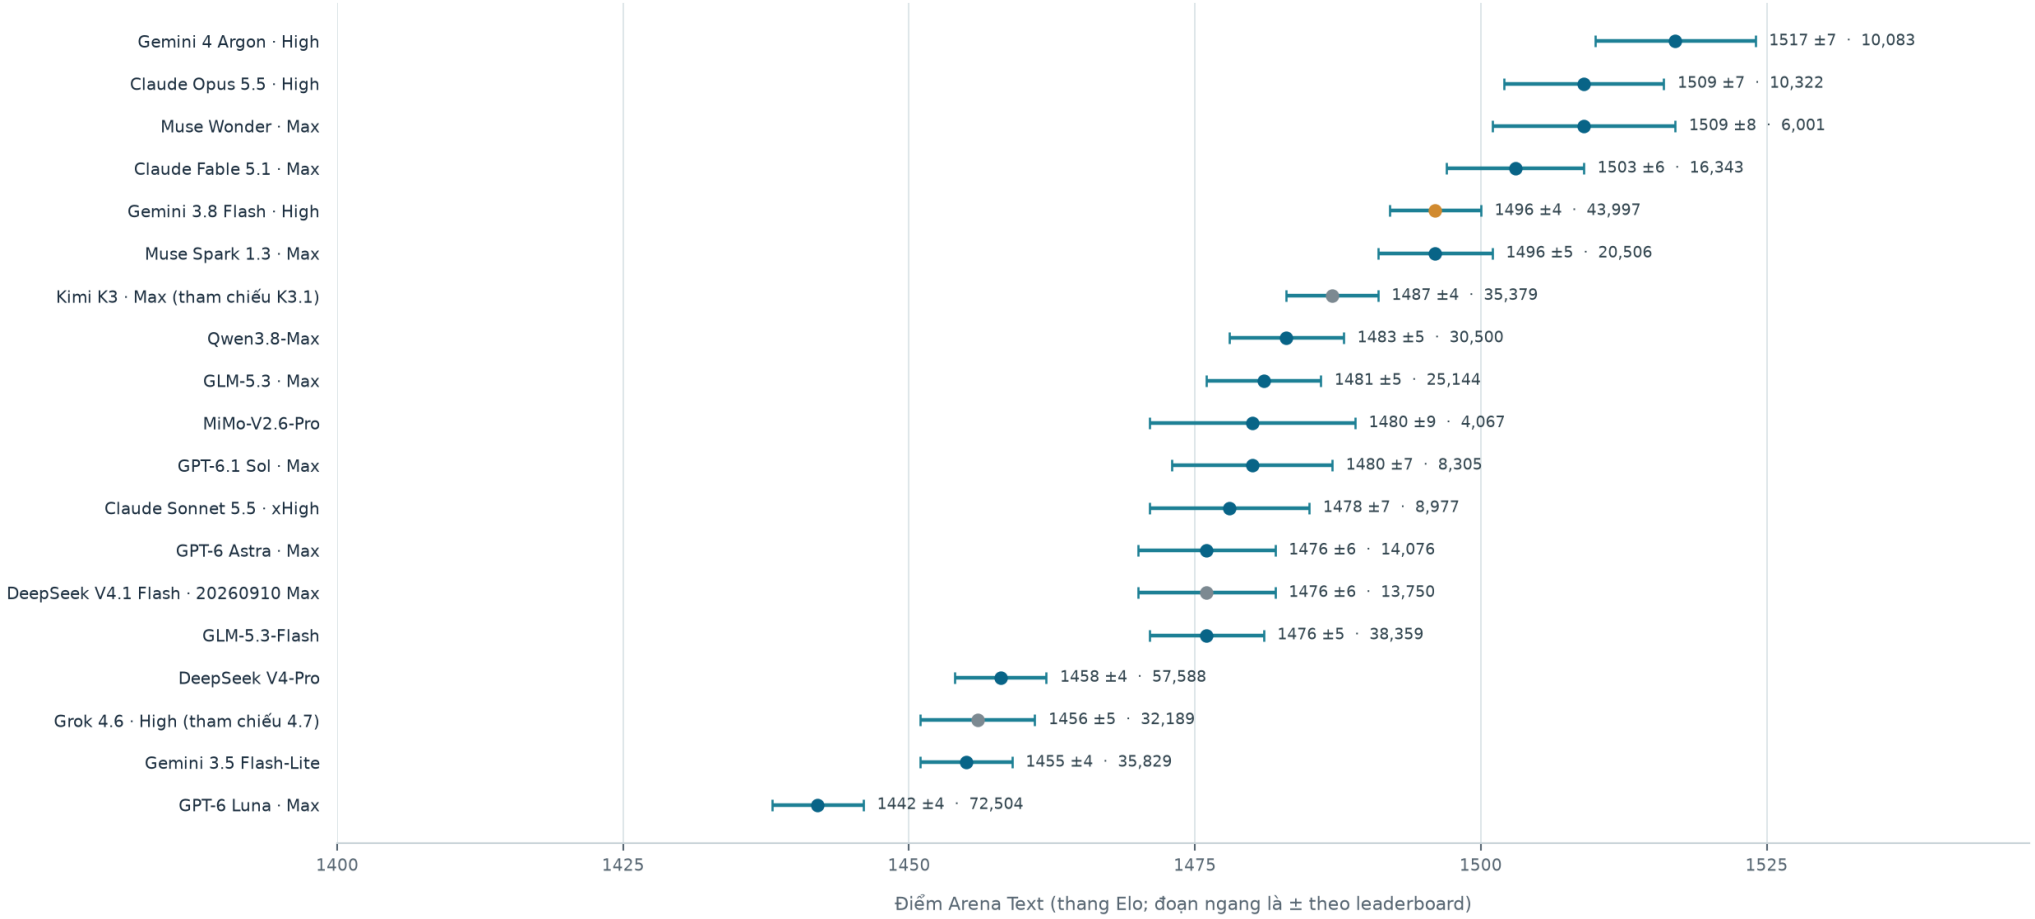
Cách dùng tài liệu

1. Xem biểu đồ Arena để chọn model cần thử. 2. So biểu đồ giá theo đúng tải token của bạn. 3. Đọc cột điều kiện và trang điều khoản ẩn trước khi chọn model production. Mọi dấu gạch ngang ở cột Arena nghĩa là chưa có điểm cho đúng phiên bản trong ảnh chụp, không phải điểm 0.

01 / BENCHMARK CHUNG

Arena Text: điểm sở thích, không phải độ chính xác tuyệt đối

Ảnh chụp leaderboard ngày 22/10/2026: 8,946,356 phiếu trên 418 model. Trục ngang là điểm Elo; thanh ngang biểu diễn ± như leaderboard công bố; số bên phải là điểm và số phiếu của từng cấu hình.



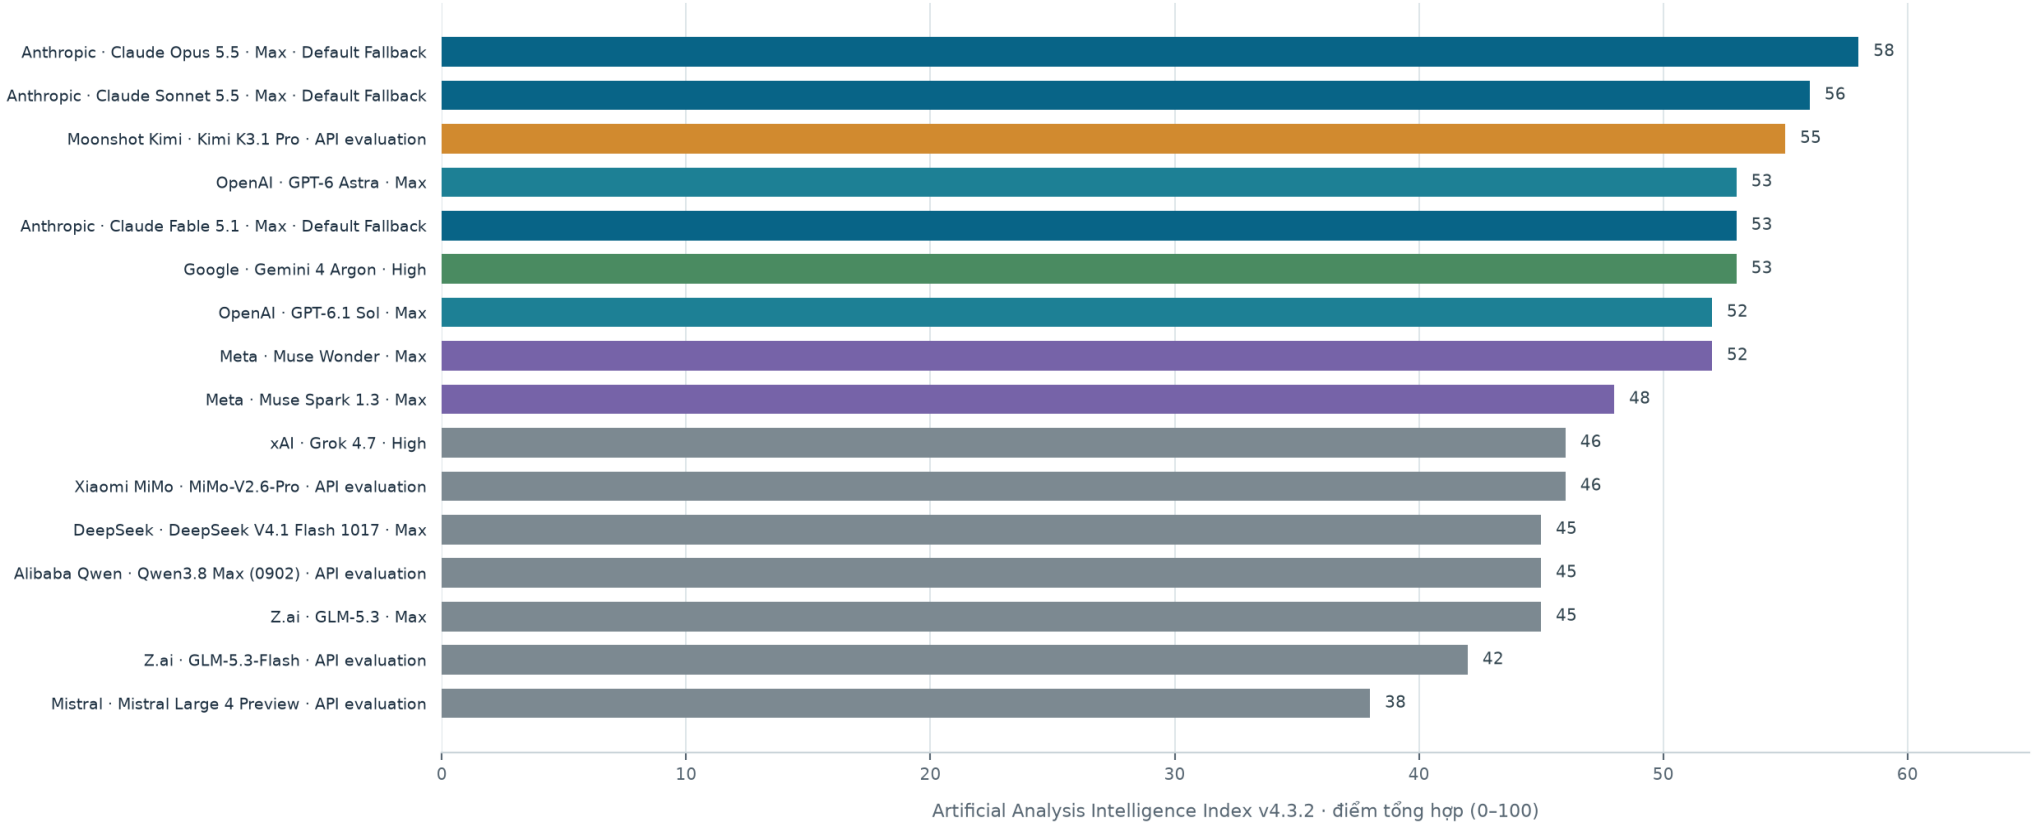
Nguồn: Arena Text leaderboard. Cấu hình High/Max/xHigh khác nhau và số phiếu mỗi model không bằng nhau. Gemini 3.8 Flash được đánh dấu sơ bộ. Kimi K3, Grok 4.6 và DeepSeek Flash 20260910 là model/phiên bản tham chiếu; điểm của chúng không được gán cho Kimi K3.1 Pro, Grok 4.7 hoặc alias DeepSeek hiện tại.

Giới hạn diễn giải: Arena Text tổng hợp lựa chọn người dùng trong các tác vụ text mở như toán, code, viết và yêu cầu khác. Điểm không chứng minh factuality, độ ổn định, an toàn, chất lượng tiếng Việt hay hiệu quả trong workflow của bạn. Đoạn ± chồng lấn thì không nên xếp hạng cứng. phạm vi và phương pháp Arena

02 / BENCHMARK TỔNG HỢP

Artificial Analysis Intelligence Index v4.3.2

Điểm tổng hợp từ 10 bài đo độc lập về agent, coding, kiến thức, khoa học và suy luận. Biểu đồ hiển thị 16 model trong tài liệu có điểm công khai và đúng phiên bản/cấu hình được xác định; nhãn model mở trang điểm gốc.



Nguồn biểu đồ: leaderboard Artificial Analysis v4.3.2 · phương pháp và trọng số

Điều kiện đọc: Đây là composite có thang 0–100, không phải tỷ lệ trả lời đúng. Bản v4.3.2 chủ yếu dùng tác vụ tiếng Anh; 45% trọng số đến từ câu hỏi/đáp án riêng tư. Effort và fallback được ghi riêng vì có thể làm thay đổi điểm. Không so số điểm này trực tiếp với Elo Arena.

03 / ĐIỂM TỔNG THEO MODEL

Các model trong danh sách có điểm AA công khai

Thứ tự giảm dần theo Artificial Analysis Intelligence Index v4.3.2. Chỉ 16 model có trang kết quả khớp model/cấu hình được xác minh được đưa vào; model vắng mặt không bị hiểu là điểm 0. Hãy mở tên model để xem trang số liệu và cấu hình cụ thể.

Hạng	Nhà cung cấp	Model và cấu hình được đo	AA Index (0–100)
1	Anthropic	Claude Opus 5.5 Max · Default Fallback	58
2	Anthropic	Claude Sonnet 5.5 Max · Default Fallback	56
3	Moonshot Kimi	Kimi K3.1 Pro API evaluation	55
4	OpenAI	GPT-6 Astra Max	53
5	Anthropic	Claude Fable 5.1 Max · Default Fallback	53
6	Google	Gemini 4 Argon High	53
7	OpenAI	GPT-6.1 Sol Max	52
8	Meta	Muse Wonder Max	52
9	Meta	Muse Spark 1.3 Max	48
10	xAI	Grok 4.7 High	46
11	Xiaomi MiMo	MiMo-V2.6-Pro API evaluation	46
12	DeepSeek	DeepSeek V4.1 Flash 1017 Max	45
13	Alibaba Qwen	Qwen3.8 Max (0902) API evaluation	45
14	Z.ai	GLM-5.3 Max	45
15	Z.ai	GLM-5.3-Flash API evaluation	42
16	Mistral	Mistral Large 4 Preview API evaluation	38

Nguồn bảng: leaderboard AA Index · định nghĩa, phiên bản và cách tính

04 / CÁC BÀI TEST THÀNH PHẦN

Cùng 3 cấu hình flagship qua 10 bài đo

Nguồn so sánh trình bày kết quả cùng lúc cho Claude Opus 5.5 Max, Kimi K3.1 Pro và GPT-6 Astra Max. Các hàng được chia theo loại việc; không so trực tiếp Elo với phần trăm giữa những benchmark khác nhau.

Agent, công việc và coding

Bài đánh giá	Đơn vị	Claude Opus 5.5 Max	Kimi K3.1 Pro	GPT-6 Astra Max
AA-Briefcase v1.1	Elo	1,800	1,678	1,568
GDPval-AA v2.1	Elo	1,866	1,846	1,584
AutomationBench-AA	% mục tiêu hoàn tất	70%	73%	68%
Terminal-Bench 4.0	pass@1 · %	60%	67%	59%
SciCode	độ chính xác · %	67%	61%	56%

Nguồn điểm: bảng so sánh 3 model · AA-Briefcase · Terminal-Bench 4.0 và cách chạy

Kiến thức, khoa học, tài liệu và ngữ cảnh dài

Bài đánh giá	Đơn vị	Claude Opus 5.5 Max	Kimi K3.1 Pro	GPT-6 Astra Max
Humanity's Last Exam	độ chính xác · %	61%	52%	55%
GDP.pdf	tỷ lệ all-pass · %	26%	31%	31%
CritPt	độ chính xác · %	32%	25%	32%
AA-Omniscience	điểm chỉ số	46	30	43
AA-LCR v1.1	tỷ lệ đúng · %	85%	86%	81%

Nguồn điểm: bảng so sánh 3 model · phương pháp AA Index v4.3.2

Terminal-Bench 4.0 dùng 66 bài, mini-swe-agent, pass@1 trung bình qua 3 lần chạy. AA-Briefcase là benchmark công việc tri thức nhiều bước; các metric từng hàng có định nghĩa và đơn vị riêng. Kết quả này là benchmark độc lập công bố, không phải phép chạy lại trong môi trường Apero.

05 / BENCHMARK TIẾNG VIỆT

VMLU: dùng mốc lịch sử, không gán sang model mới

VMLU đánh giá năng lực tiếng Việt qua bốn bộ: Vi-MQA (kiến thức), Vi-SQuAD (đọc hiểu), Vi-DROP (suy luận) và Vi-Dialog (hội thoại). Bảng dưới chép các API baseline được leaderboard định danh rõ; điểm trung bình và bốn lát lĩnh vực hữu ích để xem phạm vi bài test.

API được đo	Ngày đo	STEM (%)	Khoa học xã hội (%)	Nhân văn (%)	Khác (%)	Trung bình (%)
GPT-4	08/01/2024	63.84	71.78	66.14	60.37	65.53
GPT-4o mini	01/08/2024	58.00	70.95	65.03	60.91	62.87
Gemini (tên ghi trên leaderboard)	30/01/2024	42.80	60.31	55.35	51.30	51.03

Nguồn bảng: leaderboard VMLU chính thức · mô tả bốn bộ dữ liệu · bài báo ACL 2025

Không dùng các dòng trên để xếp hạng API 2026 trong bảng này: GPT-4 và GPT-4o mini được đo năm 2024; tên “Gemini” trên nguồn không ghi rõ phiên bản. Bộ 28 model hiện tại chưa có kết quả VMLU công khai khớp chính xác phiên bản, prompt và cấu hình, nên cần chạy lại cùng zero-shot/few-shot setting trước khi kết luận model nào viết tiếng Việt tốt hơn.

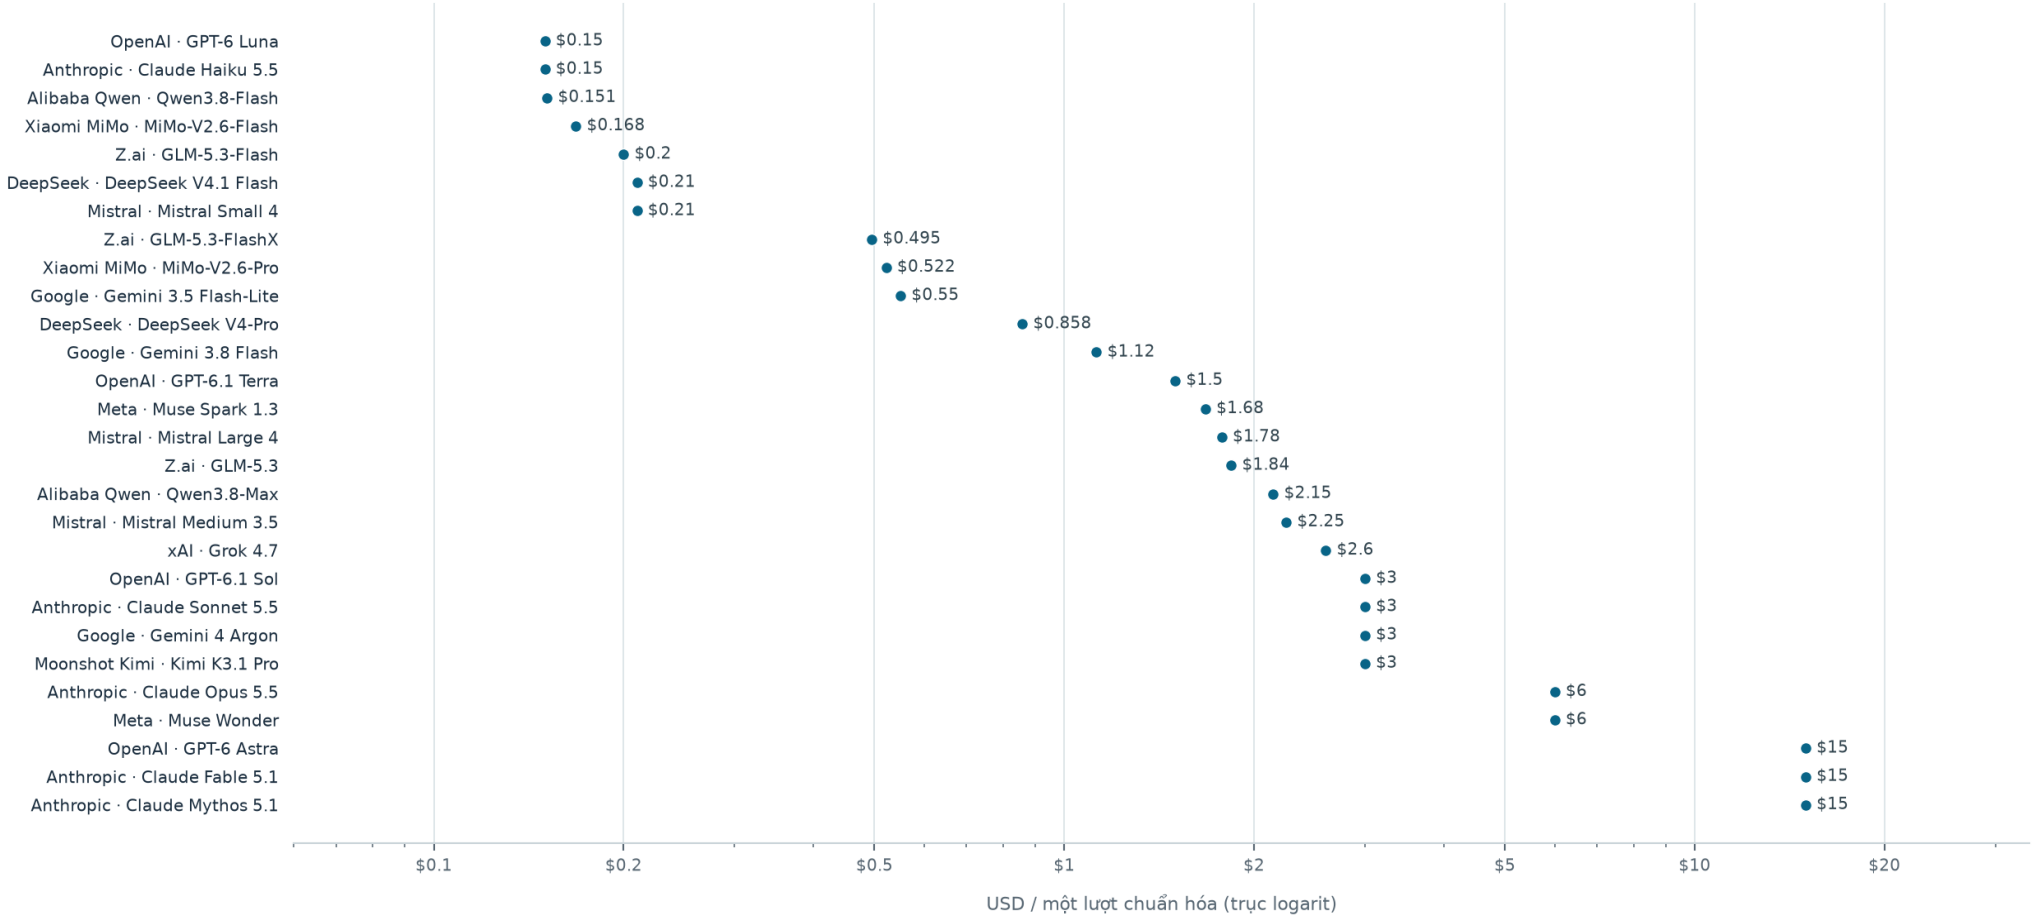
Bài kiểm tra code/agent bổ sung

SWE-bench Verified gồm 500 issue GitHub đã được người đánh giá kiểm tra. Leaderboard khuyến nghị chọn chế độ Bash-only mini-SWE-agent khi muốn đối chiếu model; các kết quả agent tổng quát và các đời harness 1.x/2.x không thể gom thành một thứ hạng model. Tại ngày chốt, tài liệu không đưa điểm nếu chưa xác định được đúng model build cùng harness. SWE-bench Verified: leaderboard và điều kiện so sánh

06 / CHI PHÍ API

Một tải mẫu để so giá input/output

Mỗi model xử lý tổng cộng 1,000,000 input token và 100,000 output token: 100 request × 10,000 input + 1,000 output. Chi phí = input rate × 1 + output rate × 0.1. Giá chuẩn là API trực tiếp; giá theo vùng, thời điểm hoặc gói riêng được ghi trong bảng model.



Giá trên trục logarit để cùng nhìn được mức dưới $0.20 và mức $15. Không tính cache, tool/web search, phí storage, thuế, retry, batch hay latency premium. DeepSeek dùng off-peak; Grok dùng prompt ngắn hơn 200K; Qwen dùng Global; Gemini dùng giá standard hiện hành; Haiku dùng request dưới 100K. Hai model có cùng chi phí vẫn có thể cho chất lượng, tốc độ và giới hạn khác nhau.

Ví dụ điều chỉnh: DeepSeek Flash peak là $0.42 thay vì $0.21; Grok 4.7 với prompt ≥200K là $5.20 thay vì $2.60; Gemini 4 Argon từ 01/12/2026 là $6.00 thay vì $3.00. DeepSeek · xAI · Google

06A.1 / GÓI THUÊ BAO

Phí tháng, hạn mức thật và cách tính API

Giá USD là giá web Hoa Kỳ được hãng công bố, chưa cộng thuế; có thể khác theo quốc gia, tỷ giá và cửa hàng ứng dụng. Kimi giữ CNY. Hạn mức theo lượt, compute hoặc credit nội bộ không thể tự đổi thành token API.

HÃNG	GÓI VÀ GIÁ THÁNG	HẠN MỨC ĐƯỢC CÔNG BỐ	LIÊN HỆ VỚI API	NGUỒN
OpenAI	Plus $20 Pro $100 / $200 / $500	Giới hạn theo model và tính năng, không phải số token cố định. Work/Codex Plus có ước tính theo cửa sổ 5 giờ; Pro vẫn có allowance nhưng hiện không có giới hạn 5 giờ ở Work/Codex.	API Platform có billing riêng. Bảng hòa vốn dùng GPT-6 Astra Standard làm mốc.	Plus · Pro · Hạn mức · API
Anthropic	Pro $20 Max 5x $100 Max 20x $200	Pro/Max dùng giới hạn phiên 5 giờ và giới hạn tuần; Max 5x/20x là bội số capacity theo phiên, không phải bội số token API.	Max có credit API thật $100/$200 mỗi tháng sau khi claim; xem bảng quota riêng. Pro không có credit này.	Giá · Hạn mức · API credit
Google	AI Pro $19.99 AI Ultra $99.99 / $199.99	AI Pro quảng bá 4x mức chuẩn; AI Ultra 5x hoặc 20x mức Pro. Gemini Apps đo theo compute, có reset 5 giờ và trần tuần, hạn mức có thể đổi.	Gói không công bố quota API bằng token; Gemini API được tính qua project/billing của AI Studio theo mức dùng.	Giá · Hạn mức · API billing
xAI / X	Plus $8 Premium $30 Super $100 Ultra $200	Pool tuần dùng chung giữa Grok và Cursor; mức Plus / 4x / 15x / 50x Plus. Khối lượng dùng phụ thuộc từng tính năng.	Grok subscription và xAI API có billing riêng; model bên thứ ba trong Cursor tính riêng.	Giá · Pool · API
Z.ai	Lite $12.60 (giá gốc $18) Pro $56 ($80) Max $117.60 ($168)	Lite công bố 10,000 credit/tuần; Pro 6x và Max 14x Lite. Credit Coding Plan là quota sản phẩm, không có quy đổi công khai sang token API.	Chỉ dùng đúng chế độ Coding Plan. API key tiêu chuẩn theo rate card có billing riêng.	Giá/credit · Chế độ
Xiaomi MiMo	Lite $6 Standard $16 Pro $50 Max $100	Quota tháng lần lượt 4.1B / 11B / 38B / 82B credit; có hệ số đổi theo model và input/output. Ví dụ MiMo V2.6 Pro: 300 credit/input, 600/output khi cache miss.	Token Plan dành cho coding tools; API pay-as-you-go dùng balance và key thường riêng. Quy đổi quota thật ở bảng kế tiếp.	Giá/quota · Đổi credit · API
Kimi	Andante CNY 49 Moderato CNY 99 Allegretto CNY 199 Allegro CNY 699	Membership dùng credit chung cho tính năng Kimi; tài liệu không công bố pool theo token API cố định. Giá trong bảng giữ CNY, không tự đổi FX.	Kimi Code và Kimi Open Platform là hai hệ thống khác nhau; không gán credit membership cho hóa đơn API.	Gói/credit · API tách riêng

Nguồn giá gói: ChatGPT Plus price and limits · ChatGPT Pro tiers and prices · Claude plan prices and capacities · Google AI Pro and Ultra prices · Gemini API project billing · The X Subscription prices and tiers · Z.ai GLM Coding Plan prices and credits · Xiaomi MiMo Token Plan prices and quotas · Kimi membership prices and shared credits

Cách đọc cột quota: ChatGPT, Claude Pro, Gemini Apps, X và GLM Coding Plan có meter theo sản phẩm, model, phiên hoặc tuần; không có một lượng token API cố định để quy đổi trực tiếp. API rate ở mục sau chỉ dùng để tính mức hòa vốn chi phí. Claude Max và Xiaomi có quota API/credit số cụ thể nên được tách riêng.

06A.2 / GIÁ API LÀM MỐC

Một tải giống nhau để tính giá trị sử dụng

Tải mẫu = 1,000,000 input + 100,000 output token, tương đương 100 request x 10,000 input + 1,000 output. Chi phí = input MTok x giá input + output MTok x giá output.

HÃNG / MODEL API	INPUT / OUTPUT (USD / MTok)	CHI PHÍ TẢI MẪU	ĐIỀU KIỆN GIÁ	NGUỒN
OpenAI GPT-6 Astra	$10 / $50	$15	Standard; prompts below 272K	rate card API
Anthropic Claude Opus 5.5	$4 / $20	$6	Standard; Opus 5.5	rate card API
Google Gemini 4 Argon	$2 / $10	$3	$2/$10 through 30/11/2026; $4/$20 from 01/12/2026	rate card API
xAI Grok 4.7	$2 / $6	$2.6	Standard global endpoint; prompt below 200K	rate card API
Z.ai GLM-5.3	$1.4 / $4.4	$1.84	Standard API list rate	rate card API
Xiaomi MiMo MiMo-V2.6-Pro	$0.435 / $0.87	$0.522	Overseas real-time API; cache miss	rate card API

Nguồn rate card API trực tiếp: OpenAI API pricing · Claude API pricing · Gemini API pricing · xAI API pricing · Z.ai model and tool pricing · Xiaomi MiMo API pricing

Điều kiện chuẩn hóa: USD / 1 triệu token, giá Standard trực tiếp, không cache, không batch, không tool/search, không thuế, không retry và không phí vùng. Mỗi request mẫu thấp hơn ngưỡng long-context được ghi ở bảng; thinking token được tính theo quy tắc của hãng. Gemini 4 Argon là giá mở đầu $2/$10 đến 30/11/2026; từ 01/12/2026 là $4/$20.

06A.3 / QUOTA QUY ĐỔI ĐƯỢC

Credit API thật và quota token có thể tính ra tải

Chỉ hai nhóm dưới đây công bố lượng API credit hoặc credit token đủ rõ để tính trực tiếp. Mỗi tải vẫn dùng cùng mẫu 1M input + 0.1M output; các con số của hai hệ credit khác nhau không thể so trực tiếp với nhau.

GÓI	PHÍ THÁNG	QUOTA / CREDIT THẬT	TẢI MẪU TƯƠNG ĐƯƠNG	GIÁ TRỊ API THAM CHIẾU	NGUỒN
Claude Max 5x Claude Platform	$100	$100 API credit / tháng	16.7 tải theo Opus 5.5	$100 credit dùng được cho API sau khi claim	Credit/điều kiện · Giá API
Claude Max 20x Claude Platform	$200	$200 API credit / tháng	33.3 tải theo Opus 5.5	$200 credit dùng được cho API sau khi claim	Credit/điều kiện · Giá API
MiMo Lite	$6	4.1B credit / tháng	11.4 tải theo MiMo V2.6 Pro	$5.95 theo rate card; phí gói $6	Gói/quota · Hệ số · Giá API
MiMo Standard	$16	11B credit / tháng	30.6 tải theo MiMo V2.6 Pro	$15.95 theo rate card; phí gói $16	Gói/quota · Hệ số · Giá API
MiMo Pro	$50	38B credit / tháng	105.6 tải theo MiMo V2.6 Pro	$55.1 theo rate card; phí gói $50	Gói/quota · Hệ số · Giá API
MiMo Max	$100	82B credit / tháng	227.8 tải theo MiMo V2.6 Pro	$118.9 theo rate card; phí gói $100	Gói/quota · Hệ số · Giá API

Nguồn quota và giá API: Monthly API credits for Claude Max and Team · Claude API pricing · Xiaomi MiMo Token Plan prices and quotas · Xiaomi Token Plan credit deductions · Xiaomi MiMo API pricing

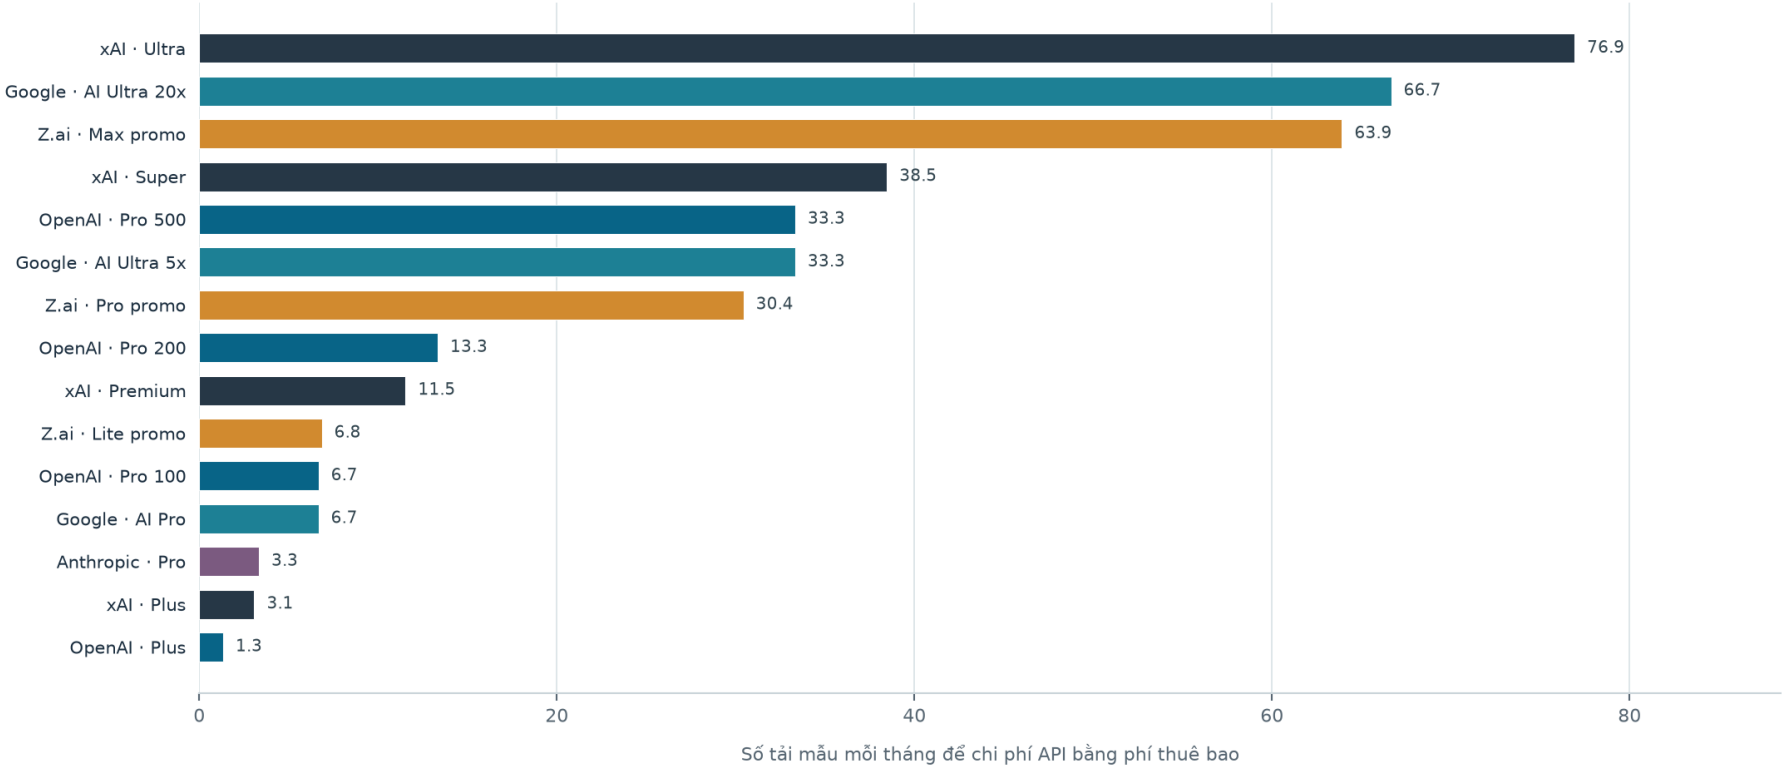
Claude Max: $100/$200 là credit API thật sau khi claim sau 7 ngày; gắn được một Console organization, hết hạn cuối chu kỳ, không dùng cho Claude Code/Cowork tương tác. Xiaomi: một tải MiMo V2.6 Pro cache miss tiêu thụ 360M credit. Bảng giả định dùng toàn quota trên model này; quota thực được chia sẻ giữa model, và giờ thấp điểm có hệ số 0.8. Token Plan là gói cho coding tools, còn API standard key dùng balance riêng.

Không quy đổi Kimi membership CNY sang token API: các credit membership dùng trong sản phẩm Kimi, Kimi Code và Open Platform API là hệ thống riêng. Mistral Vibe chia allowance tháng giữa Studio, API và Vibe Code; số hiện hành xem trong billing của từng organization. Kimi membership · Kimi API separation · Mistral subscription usage

06A.4 / HÒA VỐN THEO GIÁ API

Mỗi tháng cần bao nhiêu tải để phí gói ngang hóa đơn API?

Phép tính: phí thuê bao tháng / chi phí một tải mẫu ở cùng hãng. Biểu đồ chỉ là ngưỡng chi phí tương đương, không phải số token hoặc request được gói bao gồm. Tải mẫu của các model khác nhau không đại diện cùng chất lượng hay cùng giá trị công việc.



Nguồn gói và rate card API: ChatGPT Plus price and limits · ChatGPT Pro tiers and prices · Claude plan prices and capacities · Google AI Pro and Ultra prices · The X Subscription prices and tiers · Z.ai GLM Coding Plan prices and credits · OpenAI API pricing · Claude API pricing · Gemini API pricing · xAI API pricing · Z.ai model and tool pricing

Không phải quota API đi kèm: phí thuê bao còn mua quyền truy cập app, công cụ, lưu trữ hoặc dịch vụ khác; các meter có thể tính compute, reasoning, tốc độ, context và reset theo tuần. Claude Max được tách khỏi biểu đồ vì có API credit thật; Xiaomi được tính theo quota credit thật ở trang trước. Giá Google trong biểu đồ dùng ưu đãi API tới 30/11; từ 01/12/2026, số tải hòa vốn giảm một nửa. Giá Z.ai dùng mức khuyến mại đang hiển thị, chưa cộng thuế.

07 / CÁC MODEL ĐƯỢC CHỌN

OpenAI · Anthropic · Google

Giá ghi theo thứ tự input / output trên một triệu token. Cấu hình Arena được ghi riêng; mức giá trong bảng là giá rate card hiện hành, không lấy số giá hiển thị trên leaderboard. Mỗi model và giá đều có link đến tài liệu nhà cung cấp.

Hãng / model và ID	Input / output (USD / MTok)	Arena Text (config; phiếu)	Định vị và điều kiện cần biết	Nguồn trực tiếp
GPT-6 Astra gpt-6-astra	$10 / $50 Standard	1476 ±6 Max n=14,076	Lập luận sâu, code khó, công việc chuyên môn nhiều bước. Trên 272K input: hệ số 2x input/cache, 1.5x output cho cả request.	model · giá
GPT-6.1 Sol gpt-6.1-sol	$2 / $10 Standard	1480 ±7 Max n=8,305	Code và công việc chuyên môn; lựa chọn cân bằng giá/chất lượng. Trên 272K input: hệ số long-context; Batch/Flex rẻ hơn, Fast đắt hơn.	model · giá
GPT-6.1 Terra gpt-6.1-terra	$1 / $5 Standard	—	Thị giác, computer use, viết rõ; hợp quy trình có đầu ra xác định. Computer use/tool gọi qua Responses API; tool có thể tính phí riêng.	model · giá
GPT-6 Luna gpt-6-luna	$0.1 / $0.5 Standard	1442 ±4 Max n=72,504	Phân loại, trích xuất, tác vụ lặp lại và khối lượng lớn. Trên 272K input: 2x input/cache và 1.5x output cho cả request.	model · giá
Claude Fable 5.1 claude-fable-5-1	$10 / $50 Standard	1503 ±6 Max n=16,343	Reasoning khó và tác vụ agent kéo dài. 30 ngày lưu dữ liệu; ZDR không hỗ trợ trừ khi Anthropic cho phép riêng.	model · giá
Claude Opus 5.5 claude-opus-5-5	$4 / $20 Standard	1509 ±7 High n=10,322	Agent code dài, nghiên cứu và công việc tri thức. Cache hit 5% giá input; Batch giảm 50%; US-only inference +10%.	model · giá
Claude Sonnet 5.5 claude-sonnet-5-5	$2 / $10 Standard	1478 ±7 xHigh n=8,977	Điểm xuất phát cho code, phân tích và nội dung thường ngày. Thinking tính như output; cache, Batch và khu vực làm đổi hóa đơn.	model · giá
Claude Haiku 5.5 claude-haiku-5-5	$0.1 / $0.5 Prompt ≤100K	—	Phân loại, trích xuất, định tuyến và phản hồi độ trễ thấp. Prompt >100K: $0.50/$2.50; mọi input trong request tính vào ngưỡng.	model · giá
Claude Mythos 5.1 claude-mythos-5-1	$10 / $50 Standard; gated	—	Model hạn chế quyền truy cập; ưu tiên tác vụ nâng cao được duyệt. Chỉ tổ chức đã xác minh; 30 ngày lưu dữ liệu; ZDR mặc định không áp dụng.	model · giá
Gemini 4 Argon gemini-4-argon	$2 / $10 Tới 30/11/2026	1517 ±7 High n=10,083	Engineering, khoa học và agent nhiều bước. Từ 01/12 giá $4/$20; thinking và khai báo tool cũng được tính token.	model · giá
Gemini 3.8 Flash gemini-3.8-flash	$0.75 / $3.75 Tới 31/12/2026	1496 ±4 High · sơ bộ n=43,997	Agent tự hành, software engineering và workflow dài. Từ 01/01/2027 giá $1.50/$7.50; Search/Maps grounding có thể tính riêng.	model · giá
Gemini 3.5 Flash-Lite gemini-3.5-flash-lite	$0.3 / $2.5 Standard	1455 ±4 n=35,829	Dịch, xử lý dữ liệu đơn giản và agent lưu lượng cao. Batch/Flex $0.15/$1.25; free tier dùng dữ liệu để cải thiện sản phẩm.	model · giá

07 / CÁC MODEL ĐƯỢC CHỌN

Meta · xAI · DeepSeek · Qwen · Z.ai

Các hãng này có điều kiện về chế độ dữ liệu, vùng triển khai, giờ cao điểm và mức giá cache. Cột ghi chú nêu khác biệt đáng kiểm tra trước khi đưa vào dự toán.

Hãng / model và ID	Input / output (USD / MTok)	Arena Text (config; phiếu)	Định vị và điều kiện cần biết	Nguồn trực tiếp
Muse Wonder muse-wonder-1.0	$4 / $20 Standard	1509 ±8 Max n=6,001	Model API cao cấp; đánh giá trên workflow agent và ngữ cảnh dài. API pay-as-you-go khác subscription Muse Code; web search tính thêm.	model · giá
Muse Spark 1.3 muse-spark-1.3	$1.25 / $4.25 Standard	1496 ±5 Max n=20,506	Mức giá thấp hơn Muse Wonder; nên benchmark trên task thực tế. Contributor rẻ hơn nhưng prompt/code/files/responses có thể dùng train.	model · giá
Grok 4.7 grok-4.7	$2 / $6 Prompt <200K	— 4.6: 1456 ±5	Model mới nhất trong nhóm Grok; kiểm tra trên tác vụ agent và code. Từ 200K prompt: $4/$12; endpoint US regional thêm 10%.	model · giá
DeepSeek V4.1 Flash deepseek-flash → 1017	$0.15 / $0.6 Off-peak	— 20260910: 1476 ±6	Lựa chọn chi phí thấp; hỗ trợ thinking và non-thinking. Peak gấp đôi; current alias trỏ tới V4.1-Flash-1017.	model · giá
DeepSeek V4-Pro deepseek-v4-pro	$0.66 / $1.98 Off-peak; rate card	1458 ±4 n=57,588	Model V4-Pro theo bảng giá API; xác minh route trong console. Peak $1.32/$3.96; tài liệu release và rate card có khác biệt về routing.	model · giá
Qwen3.8-Max qwen3.8-max	$1.65 / $4.95 Global deployment	1483 ±5 n=30,500	Model cao cấp; cả thinking và non-thinking; cửa sổ tới 1M. US deployment $2/$6; giá thay đổi theo vùng và free quota có hạn.	model · giá
Qwen3.8-Flash qwen3.8-flash	$0.113 / $0.382 Global deployment	—	Tầng Flash chi phí thấp cho lưu lượng cao. Hong Kong/EU/US $0.15/$0.47; cache và batch có mức riêng.	model · giá
GLM-5.3 glm-5.3	$1.4 / $4.4 Standard	1481 ±5 Max n=25,144	Flagship cho software engineering và tác vụ agent phức tạp. Reasoning luôn bật; không tắt được; chọn effort low/high/max.	model · giá
GLM-5.3-Flash glm-5.3-flash	$0.15 / $0.5 Standard	1476 ±5 n=38,359	Biến thể chi phí thấp; benchmark riêng trên tác vụ đích. Cache storage đang miễn phí có thời hạn; cache hit có giá riêng.	model · giá
GLM-5.3-FlashX glm-5.3-flashx	$0.37 / $1.25 Standard	—	Biến thể FlashX; so latency và chất lượng với Flash. Giá list khác mức giá có thể hiển thị trên leaderboard.	model · giá

DeepSeek: bảng giá hiện hành liệt kê cả Flash và V4-Pro; một số release note trước đó mô tả việc đổi route. Nếu chọn V4-Pro, kiểm tra ID/route thực tế ở console và log request. Giá biểu đồ giữ theo rate card mới nhất; ghi rõ off-peak.

07 / CÁC MODEL ĐƯỢC CHỌN

Mistral · Kimi · Xiaomi MiMo

Các rate dưới đây dùng API pay-as-you-go trực tiếp. Không cộng subscription, token plan hoặc Batch vào mức giá chuẩn.

Hãng / model và ID	Input / output (USD / MTok)	Arena Text (config; phiếu)	Định vị và điều kiện cần biết	Nguồn trực tiếp
Mistral Large 4 mistral-large-4	$1.36 / $4.18 Standard; preview	—	Open-weight, general-purpose multimodal, 1M context. Public Preview; tính năng/giá có thể đổi khi ra bản ổn định.	model · giá
Mistral Medium 3.5 mistral-medium-3.5	$1.5 / $7.5 Standard	—	Generalist cho reasoning, code, tool use và agentic tasks. Batch và Priority là các chế độ giá khác; bảng dùng Standard.	model · giá
Mistral Small 4 mistral-small-4	$0.15 / $0.6 Standard	—	Generalist giá thấp hơn trong nhóm Mistral. Cache có giá riêng; Batch/Priority khác Standard.	model · giá
Kimi K3.1 Pro kimi-k3.1-pro	$2 / $10 Standard API	— K3: 1487 ±4	Reasoning, coding, research và tác vụ dài; context 1M. API tính pay-as-you-go, tách khỏi membership/Kimi Code; chưa có Arena score cùng phiên bản.	model · giá
MiMo-V2.6-Pro mimo-v2.6-pro	$0.435 / $0.87 Overseas, real-time	1480 ±9 n=4,067	Flagship multimodal reasoning; context 1M, output tối đa 128K. Pay-as-you-go tách Token Plan; cache hit $0.0036/M input.	model · giá
MiMo-V2.6-Flash mimo-v2.6-flash	$0.14 / $0.28 Overseas, real-time	—	Biến thể Flash rẻ hơn cho lưu lượng lớn. Batch giảm 50%; cache hit và Token Plan có biểu giá khác.	model · giá

Những khác biệt dễ bị bỏ sót

Mistral Large 4 đang là Public Preview; Xiaomi MiMo API và Token Plan là hai ví khác nhau; Kimi API tách khỏi membership/Kimi Code. Với Kimi K3.1 Pro, leaderboard hiện có điểm cho Kimi K3 đời trước chứ chưa có điểm cùng phiên bản. Xiaomi MiMo-V2.6-Pro có điểm Arena và model card công bố context 1M, output tối đa 128K.

Nguồn: Mistral Large 4 · Kimi K3.1 Pro · MiMo-V2.6-Pro · MiMo billing rules

08 / ĐIỀU KIỆN NGẦM

Những điểm làm giá, quyền truy cập hoặc dữ liệu đổi đi

Giá niêm yết chỉ là một phần của tổng chi phí. Đọc đúng từng điều kiện này trước khi so sánh hai API.

ĐIỀU KIỆN	TÁC ĐỘNG THỰC TẾ	NGUỒN
Ngưỡng prompt	Claude Haiku 5.5: trên 100K input trong một request (kể cả cache) đổi toàn request sang $0.50/$2.50. Grok 4.7: từ 200K đổi sang $4/$12. OpenAI: trên 272K áp dụng 2x input/cache và 1.5x output cho cả request.	tài liệu gốc
Thinking và tools	Thinking/reasoning tokens thường được tính vào output. Prompt system, schema tool, kết quả truy xuất và tool output cũng là token input; web search/grounding có thể có phí theo lượt riêng.	tài liệu gốc
Cache không đồng nghĩa miễn phí	Cache write, cache hit và thời hạn cache có rate riêng. Claude có cache write 5 phút/1 giờ; Kimi K3 có cache theo TTL; Google implicit cache có phí lưu trữ; Xiaomi cache-hit rẻ hơn input miss.	tài liệu gốc
Batch và tốc độ	Batch/Flex thường rẻ hơn nhưng không tương đương latency của request đồng bộ. Google Flash-Lite Batch/Flex là $0.15/$1.25; Mistral có Standard/Batch/Priority; Xiaomi Batch giảm 50%.	tài liệu gốc
Dữ liệu dùng để cải thiện model	Google Free tier ghi dùng nội dung để cải thiện sản phẩm, Paid tier ghi không. Meta Contributor mode cho phép dùng prompt, code, file/context và phản hồi để train model tương lai; Standard mode không dùng nội dung để train.	tài liệu gốc
Vùng và thời điểm	Qwen khác giá Global/US; DeepSeek off-peak bằng một nửa peak; Grok US regional endpoint +10%; Claude US-only inference +10%. So đúng endpoint và múi giờ.	tài liệu gốc
Model bị giới hạn	Claude Mythos 5.1 chỉ dành cho tổ chức đã xác minh và yêu cầu retention 30 ngày. Mistral Large 4 hiện Public Preview. Bản preview hoặc gated có thể đổi quyền truy cập/rate.	tài liệu gốc
API khác subscription	Model API trả theo token không nhất thiết nằm trong gói chat/seat. Kimi API tách membership/Kimi Code; Xiaomi API pay-as-you-go tách Token Plan; Meta Model API khác Muse Code subscription.	tài liệu gốc
Tên alias và phiên bản	Alias có thể chuyển sang phiên bản backend mới. DeepSeek `deepseek-flash` hiện trỏ V4.1-Flash-1017; điểm Arena cũ cho bản 20260910 không phải phép đo cùng build.	tài liệu gốc
Token không đồng nhất	Một triệu token của model này không bằng một triệu từ hoặc ký tự của model khác. Ngôn ngữ, tokenizer, ảnh/video, reasoning và lịch sử hội thoại làm thay đổi lượng token tính tiền.	tài liệu gốc

Đơn vị API trực tiếp; không phải báo giá hợp đồng

Một nhà cung cấp có thể đổi giá theo endpoint cloud/region, thỏa thuận volume, processing tier hoặc thuế. Các số trong PDF là giá công khai của API trực tiếp tại thời điểm kiểm tra. Không dùng chúng để kết luận tổng chi phí production khi chưa đưa cache, tỷ lệ thinking, tool calls, latency, retry và data residency vào cùng mô hình.

09 / DÙNG ĐÚNG KẾT QUẢ

Từ shortlist sang benchmark tiếng Việt của bạn

Leaderboard toàn cầu giúp sàng lọc, nhưng không thay cho kiểm thử nội bộ. Các cấu hình reasoning, công cụ, giới hạn output và cách tính token khác nhau giữa hãng.

Quy trình so sánh gọn

01 · Chọn 3–5 model

Lấy một model mạnh, một model cân bằng và một model rẻ từ biểu đồ. Chỉ đưa vào shortlist những model đáp ứng privacy, vùng dữ liệu, latency và API/tool requirements.

02 · Khóa cùng điều kiện

Dùng cùng bộ prompt tiếng Việt, dữ liệu, system prompt, công cụ, giới hạn token, reasoning effort, retry policy và môi trường chấm. Ghi rõ model ID, không chỉ tên thương mại.

03 · Chấm đầu ra

Đánh giá độ đúng, mức làm theo yêu cầu, lỗi nghiêm trọng, chất lượng tiếng Việt, độ ổn định qua nhiều lượt và khả năng gọi tool. Với tác vụ có đáp án, dùng kiểm tra tự động; với tác vụ mở, dùng rubric và đánh giá mù.

04 · Đo hóa đơn thật

Ghi input/output/reasoning/cached tokens, phí tool/search, latency p50/p95, lỗi và retry cho mỗi tác vụ. So chi phí trên một tác vụ đạt chuẩn, không chỉ trên mỗi token.

05 · Duy trì regression

Lưu bộ prompt đại diện; chạy lại khi đổi alias, model version, endpoint, tokenizer, giá hoặc reasoning settings. Dùng version pin nếu nhà cung cấp hỗ trợ.

> Không suy ra “giá trị tốt nhất” từ hai biểu đồ. Arena và bảng giá có mẫu số khác nhau. Để tính chất lượng/đô la, cần chạy cùng bộ việc, cùng cấu hình và đo đúng chi phí thực tế của tổ chức.

Nguồn phương pháp và dữ liệu

Điểm và phiếu: Arena Text leaderboard. Giá model và điều kiện: trang chính thức từng hãng trong các trang nguồn tiếp theo. Công thức workload là phép tính của tài liệu, không phải báo giá của nhà cung cấp.

10 / NGUỒN GỐC (1/5)

Các nhãn dưới đây mở đúng tài liệu gốc. Giá gói và rate card API được kiểm tra ngày 28/10/2026; Arena Text dùng ảnh chụp 22/10/2026; các leaderboard AA và VMLU được kiểm tra ngày 28/10/2026.

Arena Text leaderboard https://arena.ai/leaderboard/chat/text
Arena: Arena Expert and occupational categories https://arena.ai/blog/arena-expert
OpenAI API model catalog https://developers.openai.com/api/docs/models
OpenAI API pricing https://developers.openai.com/api/docs/pricing
Claude model overview https://platform.claude.com/docs/en/models/overview
Claude API pricing https://platform.claude.com/docs/en/about-claude/pricing
Anthropic API data retention and ZDR https://platform.claude.com/docs/en/manage-claude/api-and-data-retention
Gemini API model catalog https://ai.google.dev/gemini-api/docs/models
Gemini API pricing https://ai.google.dev/gemini-api/docs/pricing
Meta Model API models https://dev.meta.ai/docs/models
Meta Model API pricing and rate limits https://dev.meta.ai/docs/pricing-rate-limits
xAI API model catalog https://docs.x.ai/developers/models
xAI API pricing https://docs.x.ai/developers/pricing

10 / NGUỒN GỐC (2/5)

Các nhãn dưới đây mở đúng tài liệu gốc. Giá gói và rate card API được kiểm tra ngày 28/10/2026; Arena Text dùng ảnh chụp 22/10/2026; các leaderboard AA và VMLU được kiểm tra ngày 28/10/2026.

DeepSeek API models and pricing https://api-docs.deepseek.com/quick_start/pricing/
DeepSeek API updates https://api-docs.deepseek.com/updates/
Alibaba Cloud Model Studio inference pricing https://www.alibabacloud.com/help/en/model-studio/model-pricing
Z.ai GLM-5.3 model guide https://docs.z.ai/guides/llm/glm-5.3
Z.ai model and tool pricing https://docs.z.ai/guides/overview/pricing
Mistral Large 4 model card https://docs.mistral.ai/models/mistral-large
Mistral API pricing https://docs.mistral.ai/inference/pricing
Kimi K3.1 Pro API guide https://platform.kimi.ai/docs/guide/kimi-k3-1-pro-quickstart
Kimi API pricing portal https://platform.kimi.ai/docs/pricing/chat
Kimi API current model and rate card https://platform.kimi.ai/
Xiaomi MiMo-V2.6-Pro model card https://mimo.mi.com/models/en-US/mimo-v2-6-pro
Xiaomi MiMo API pricing https://mimo.mi.com/docs/pricing
Xiaomi MiMo Batch API pricing and rules https://mimo.mi.com/docs/en-US/quick-start/usage-guide/text-generation/batch-api

10 / NGUỒN GỐC (3/5)

Các nhãn dưới đây mở đúng tài liệu gốc. Giá gói và rate card API được kiểm tra ngày 28/10/2026; Arena Text dùng ảnh chụp 22/10/2026; các leaderboard AA và VMLU được kiểm tra ngày 28/10/2026.

Artificial Analysis Intelligence Index v4.3.2 leaderboard https://artificialanalysis.ai/evaluations/artificial-analysis-intelligence-index?stream=top
Artificial Analysis intelligence benchmarking methodology https://artificialanalysis.ai/methodology/intelligence-benchmarking
Artificial Analysis multi-model comparison and component scores https://artificialanalysis.ai/models/comparisons
Artificial Analysis Terminal-Bench 4.0 results and method https://artificialanalysis.ai/evaluations/terminalbench-4-0
Artificial Analysis AA-Briefcase results and method https://artificialanalysis.ai/evaluations/aa-briefcase
VMLU official leaderboard https://vmlu.ai/leaderboard
VMLU benchmark suite https://vmlu.ai/
VMLU Benchmarks paper, ACL 2025 https://aclanthology.org/2025.acl-long.563/
SWE-bench Verified leaderboard and Bash-only settings https://www.swebench.com/verified

10 / NGUỒN GỐC (4/5)

Các nhãn dưới đây mở đúng tài liệu gốc. Giá gói và rate card API được kiểm tra ngày 28/10/2026; Arena Text dùng ảnh chụp 22/10/2026; các leaderboard AA và VMLU được kiểm tra ngày 28/10/2026.

ChatGPT Plus price and limits https://help.openai.com/en/articles/6950777-what-is-chatgpt-plus
ChatGPT Pro tiers and prices https://help.openai.com/en/articles/9793128-about-chatgpt-pro-tiers
OpenAI Work and Codex usage limits https://help.openai.com/en/articles/20001516-managing-usage-with-gpt-6-astra-in-work-and-codex
ChatGPT and API billing are separate https://help.openai.com/en/articles/9039756-managing-billing-for-chatgpt-and-the-api-platform
Claude plan prices and capacities https://support.claude.com/en/articles/11049762-choose-a-claude-plan
Monthly API credits for Claude Max and Team https://support.claude.com/en/articles/17154008-monthly-api-credits-for-max-and-team-plans
Claude five-hour and weekly limits https://support.claude.com/en/articles/11647753-how-do-usage-and-length-limits-work
Google AI Pro and Ultra prices https://gemini.google/subscriptions/?hl=en&gl=US
Gemini Apps compute-based limits https://support.google.com/gemini/answer/16275805?hl=en
Gemini API project billing https://ai.google.dev/gemini-api/docs/billing

10 / NGUỒN GỐC (5/5)

Các nhãn dưới đây mở đúng tài liệu gốc. Giá gói và rate card API được kiểm tra ngày 28/10/2026; Arena Text dùng ảnh chụp 22/10/2026; các leaderboard AA và VMLU được kiểm tra ngày 28/10/2026.

The X Subscription prices and tiers https://x.ai/pricing
The X Subscription weekly usage pool https://docs.x.ai/x-subscription/usage-limits
Grok and xAI API billing separation https://docs.x.ai/console/faq/accounts
Z.ai GLM Coding Plan prices and credits https://zcode.z.ai/pricing.html
ZCode Coding Plan credits and API key mode https://zcode.z.ai/en/docs/configuration
Xiaomi MiMo Token Plan prices and quotas https://mimo.mi.com/docs/en-US/price/token-plan
Xiaomi Token Plan credit deductions https://mimo.mi.com/docs/en-US/quick-start/faq/token-plan/Usage%26Quota
Kimi membership prices and shared credits https://www.kimi.com/en/help/membership/membership-overview
Kimi Code and Open Platform are separate https://www.kimi.com/code/docs/en/kimi-code/error-reference.html
Mistral included usage shared across API and Vibe https://docs.mistral.ai/admin/billing-usage/subscriptions
Mistral Vibe plan and usage page https://mistral.ai/pricing/