TÀI LIỆU THAM KHẢO • CLAUDE API

Chọn model Claude đúng việc, đúng ngân sách

Benchmark, giá input/output và các điều kiện ảnh hưởng chi phí

Chốt số liệu: 28/10/2026 · Đơn vị giá: USD cho một triệu token (MTok) · Phạm vi: Claude API do Anthropic trực tiếp cung cấp

Không có một model tốt nhất cho mọi việc. Hóa đơn phụ thuộc vào lượng token thật sự gửi và sinh ra, thinking, cache, công cụ, khu vực suy luận và loại tác vụ. Tài liệu này tách giá niêm yết khỏi benchmark, rồi nêu những điều kiện dễ làm dự toán lệch.

Chọn nhanh

Haiku 5.5 cho phân loại, trích xuất và tác vụ lặp lại khối lượng lớn. Sonnet 5.5 là điểm bắt đầu hợp lý cho công việc thường ngày và code có phạm vi rõ. Opus 5.5 dành cho việc khó, dài hoặc cần phán đoán bền bỉ. Chỉ chuyển lên Fable 5.1 khi bài đánh giá nội bộ cho thấy Opus chưa đạt; Fable có giá token cao hơn và điều kiện lưu dữ liệu riêng.

Bốn model trong danh sách hiện hành

Model	ID trên Claude API	Input / output	Context / output tối đa	Effort mặc định trên Platform
Haiku 5.5	claude-haiku-5-5	Từ $0.10 / $0.50	1M / 128K	medium
Sonnet 5.5	claude-sonnet-5-5	$2 / $10	1M / 128K	high
Opus 5.5	claude-opus-5-5	$4 / $20	1M / 128K	medium
Fable 5.1	claude-fable-5-1	$10 / $50	1M / 128K	high

Nguồn: Model overview: ID, context, output tối đa, effort mặc định và định hướng dùng

Phạm vi giá

Bảng giá là giá niêm yết của Claude API first-party, dùng USD. Amazon Bedrock, Google Cloud do Google quản lý và nền tảng đối tác có cách tính hoặc giá khu vực riêng. Mythos 5.1 không nằm trong bảng chọn model phổ thông vì chỉ tổ chức đã xác minh mới được cấp quyền.

Nguồn: Pricing và quyền truy cập Fable/Mythos

Các số liệu benchmark ở trang sau là kết quả Anthropic công bố trong trang ra mắt từng model, không phải kết quả do tài liệu này tự chạy.

1 Benchmark: đọc điểm số cùng cấu hình

Các điểm dưới đây giúp chọn việc cần thử, không tạo ra bảng xếp hạng tuyệt đối. Effort, công cụ, agent harness, cách chấm, phiên bản bộ câu hỏi và safeguard đều có thể khác nhau. Không gộp các phiên bản khác nhau thành một điểm chung.

Điểm nổi bật trong công bố của Anthropic

Model	Terminal-Bench 4.0 code/terminal	GDPval-AA knowledge work	Humanity's Last Exam có tools
Fable 5.1	55.8%	1,853 (v2)	65.0%
Opus 5.5	66.4% (xhigh)	1,846 (v2.1)	67.7%
Sonnet 5.5	70.6%	1,844 (v2.1)	64.5%
Haiku 5.5	39.2%	1,620 (v2.1)	57.4%

Nguồn: Công bố của Anthropic: Fable, Opus, Sonnet và Haiku

GDPval-AA của Fable 5.1 trong thông báo là v2, còn ba dòng kia là v2.1. Trang Opus ghi Terminal-Bench 66.4% ở xhigh; Sonnet công bố 70.6%; Haiku 39.2%. Không kết luận Sonnet luôn tốt hơn Opus chỉ từ một điểm code. Điểm HLE là cấu hình có tools, không phải no-tools.

Nguồn: Mô tả và thay đổi phiên bản Terminal-Bench 4.0

Nguồn: Thiết kế HLE, cách chấm và giới hạn diễn giải

Một đối chiếu ngoài Anthropic: Arena Agent

Ảnh chụp leaderboard ngày 23/10/2026 xếp Opus 5.5 (Max) hạng 1, Sonnet 5.5 (Max) hạng 2 và Fable 5.1 (Max) hạng 4 trong 55 cấu hình. Bảng dùng tín hiệu từ phiên agent thật như thành công, mức hài lòng và khả năng điều hướng; số này phản ánh cả cấu hình agent, effort và cách dùng, không chỉ model API trần.

Nguồn: Arena Agent leaderboard · snapshot 23/10/2026

Cách dùng benchmark

Dùng điểm công khai để lập shortlist. Quyết định cuối dựa trên bộ tác vụ Apero đại diện, cùng prompt, tools, effort, giới hạn token và số lần thử; đo chi phí cho mỗi tác vụ đạt yêu cầu, thời gian và tỷ lệ phải làm lại.

Nguồn: Đánh giá chi phí theo task và trade-off effort

2 Giá API và một phép tính mẫu

Bảng sau là giá theo từng triệu token. Cache write tính riêng cho đoạn mới được ghi; cache read tính cho đoạn trúng cache. Batch có giá riêng cho input/output. Giá là USD/MTok.

Model / loại prompt	Input	Output	Cache read	Cache write 5 phút / 1 giờ	Batch input / output
Haiku 5.5 · đến 100K	$0.10	$0.50	$0.01	$0.125 / $0.20	$0.05 / $0.25
Haiku 5.5 · trên 100K	$0.50	$2.50	$0.05	$0.625 / $1.00	$0.25 / $1.25
Sonnet 5.5	$2.00	$10.00	$0.10	$2.50 / $4.00	$1.00 / $5.00
Opus 5.5	$4.00	$20.00	$0.20	$5.00 / $8.00	$2.00 / $10.00
Fable 5.1	$10.00	$50.00	$0.25	$12.50 / $20.00	$5.00 / $25.00

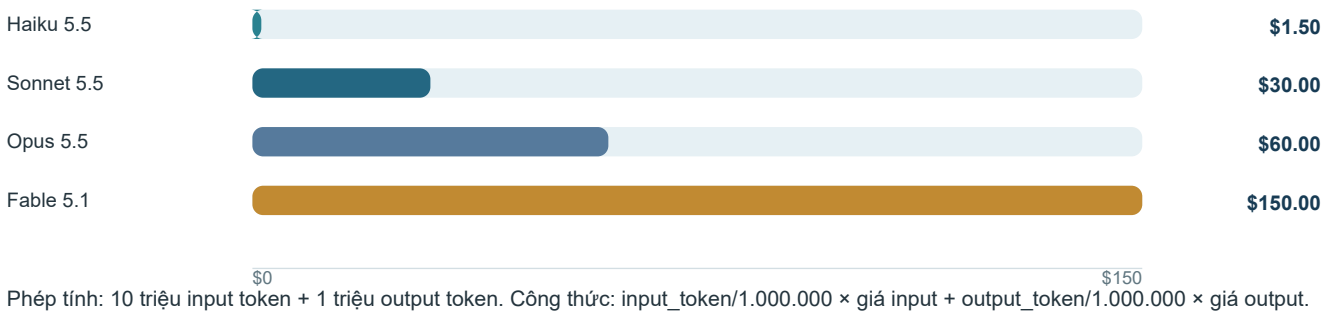
Nguồn: Pricing: model rates, cache, fast mode, Batch API và ngưỡng Haiku

Haiku 5.5 có mức giá thứ hai khi prompt của một request vượt 100.000 token. Fast mode của Opus 5.5 không nằm trong bảng thường: input $8 và output $40/MTok.

Nguồn: Giá theo ngưỡng prompt Haiku

Nguồn: Opus 5.5 fast mode

Ví dụ: 1.000 request, mỗi request có 10.000 input token mới và 1.000 output token. Không cache, batch hay tools; mỗi prompt Haiku dưới ngưỡng 100.000.



Phép tính: 10 triệu input token + 1 triệu output token. Công thức: input_token/1.000.000 × giá input + output_token/1.000.000 × giá output. Kết quả chỉ minh họa tiền token, không dự đoán chất lượng, retry hay hóa đơn thực tế.

Nguồn: Token pricing và giá sử dụng tools

3 Những điều kiện dễ làm lệch hóa đơn

Giá niêm yết là giá cho mỗi loại token. Một request thực tế có nhiều loại token và đôi khi có phụ phí ngoài token.

- **Lịch sử hội thoại được gửi lại.** Mỗi lượt mới có thể mang theo system prompt, lịch sử, tài liệu và định nghĩa tools. Token cache vẫn tính tiền, chỉ rẻ hơn input thường; cache không làm context ngắn lại.

Nguồn: Pricing và prompt caching

- **Thinking tính như output.** Token reasoning nội bộ được tính theo giá output dù không hiện thành câu trả lời. Effort cao thường tăng thời gian và lượng token; model mới dùng adaptive thinking.

Nguồn: Thinking, max_tokens và chi phí

- **Thinking cũ có thể quay lại thành input.** Model hiện hành mặc định giữ thinking blocks của lượt trước trong context; khi gửi lại, chúng chiếm context và được tính như input.

Nguồn: Context window với thinking

- **Ngưỡng Haiku tính theo từng request và gồm cache.** Nếu tổng prompt vượt 100.000 token, toàn request đó chuyển sang mức giá cao hơn; cache read và cache write cũng tính vào độ dài prompt.

Nguồn: Long-context pricing Haiku 5.5

- **Tokenizer mới đếm nhiều hơn.** Claude 4.7 trở đi dùng tokenizer mới; cùng văn bản có thể tạo khoảng 30% token nhiều hơn so với tokenizer cũ. Mức tăng thực tế tùy nội dung.

Nguồn: Ghi chú tokenizer trong Pricing

- **Tools thêm token và có thể có phí gọi.** Schema, kết quả tool và nội dung tìm kiếm đi vào usage. Web search giá $10/1.000 lượt, cộng token nội dung tìm được. Pricing còn liệt kê 286 token system overhead cho tool-use auto/none trên Opus, Sonnet và Haiku.

Nguồn: Giá web search

Nguồn: Token overhead theo model và tool choice

Context không đồng nghĩa với miễn phí

Bốn model có context window 1M token và tối đa 128K output. Đây là giới hạn kỹ thuật, không phải gói token miễn phí. Input, thinking và output đều dùng context; riêng Haiku còn có ngưỡng giá 100K.

Nguồn: Model overview và context windows

Nguồn: Cách tính input/output/thinking trong context

4 Cách giảm chi phí mà vẫn giữ chất lượng

Giảm giá mỗi token chỉ có ích khi kết quả vẫn đạt yêu cầu. Ghép đúng tác vụ với model, giữ prompt lặp lại ổn định và đo chi phí trên một đầu việc hoàn thành.

Đòn bẩy	Khi phù hợp	Điều kiện và giới hạn
Prompt cache	System prompt, tài liệu, tool schema hoặc prefix lặp qua nhiều lượt.	5 phút: write 1.25× input; 1 giờ: 2×. Read: $0.01/MTok với Haiku đến 100K, $0.10 Sonnet, $0.20 Opus, $0.25 Fable. Prefix phải giữ nguyên.
Batch API	Phân loại hoặc tạo nội dung có thể đợi.	Giảm 50% input/output; bất đồng bộ, tối đa 24 giờ. Không ghép fast mode. Hỗ trợ Claude API và Claude Platform on AWS; không hỗ trợ Bedrock, Google Cloud, Microsoft Foundry.
Global routing	Không bắt buộc suy luận chỉ tại Hoa Kỳ.	Global là mặc định, giá chuẩn. inference_geo=us nhân 1.1 lên input, output và cache từ Claude 4.6 trở đi.
Giảm effort/output	Tác vụ đơn giản hoặc có tiêu chí đúng/sai.	Thử effort thấp hơn và output vừa đủ. Thinking vẫn tính như output; max_tokens là trần, không phải phí cố định.
Fast mode	Khi tốc độ Opus 5.5 đáng giá hơn chi phí.	Tối đa 2.5× tốc độ sinh output; $8 input / $40 output mỗi MTok. Không dùng với Batch; cache và hệ số vùng vẫn cộng tiếp.

Nguồn: Prompt caching: TTL, prefix và cache hit

Nguồn: Batch API: mức giảm, SLA và nền tảng

Nguồn: Fast mode và giới hạn Batch

Nguồn: inference_geo và cache pricing

Trong ứng dụng, đặt phần prompt ổn định trước và breakpoint ở cuối prefix; đưa nội dung thay đổi ra sau. Đo usage sau vài chục lượt để xác nhận cache thật sự hit, không chỉ dựa vào việc đã bật cache.

Nguồn: Hướng dẫn prompt caching

Đo chi phí đúng hơn

So sánh chi phí mỗi tác vụ hoàn thành, không chỉ đơn giá MTok. Model đắt hơn nhưng giải quyết trong ít lượt có thể rẻ hơn tổng cộng; model mạnh cũng gây lãng phí nếu dùng cho việc lặp đơn giản.

Nguồn: Tối ưu chi phí theo workload và task

5 Hạn mức API, truy cập và dữ liệu

Rate limit API khác quota Claude Pro/Max/Team. API tính usage theo token; tốc độ gửi bị giới hạn theo RPM, input tokens per minute (ITPM) và output tokens per minute (OTPM), tùy tier và model.

Tier	Opus / Sonnet / Haiku RPM · ITPM · OTPM	Fable 5.x RPM · ITPM · OTPM
Start	1,000 · 2.0M · 0.4M	1,000 · 0.5M · 0.1M
Build	5,000 · 5.0M · 1.0M	2,000 · 1.5M · 0.3M
Scale	10,000 · 10.0M · 2.0M	4,000 · 4.0M · 0.8M

Đây là mức tối đa theo bảng tier tại ngày đối chiếu, không phải cam kết throughput. Limit có thể dùng chung theo nhóm model; vượt mức trả 429. Phần lớn model không tính cache-read token vào ITPM nhưng vẫn tính phí. Mỗi tổ chức có monthly spend cap riêng trong Console.

Nguồn: Rate limits, tier, token bucket và spend cap

Quyền truy cập và lưu dữ liệu

- **Fable 5.1:** mọi khách hàng có thể gọi trên Claude API, nhưng model yêu cầu data retention 30 ngày. Workspace bật zero data retention (ZDR) không gọi được, trừ khi Anthropic chấp thuận ngoại lệ.

Nguồn: Data retention 30 ngày và ngoại lệ ZDR

- **Mythos 5.1:** cùng specs/giá với Fable 5.1 nhưng chỉ tổ chức được xác minh theo chương trình của Anthropic mới được cấp quyền.

Nguồn: Quyền truy cập Fable/Mythos

- **Model ID:** dùng ID chính xác khi ghi log benchmark và phát hành ứng dụng. ID thế hệ mới là snapshot cố định; một số alias đời cũ có thể trỏ tới bản mới hơn.

Nguồn: Model IDs, alias và snapshot

- **Nền tảng:** giá ở đây là Claude API first-party. Bedrock và Google Cloud do Google quản lý có bảng giá/vùng riêng; marketplace có thể quy đổi hóa đơn khác.

Nguồn: Giá cloud và regional endpoints

Lưu ý trước khi dùng Fable

Fable 5.1 có thay đổi tương thích so với Fable 5, gồm forced tool use và xử lý thinking block. Kiểm tra migration guide và chính sách lưu dữ liệu trước khi đưa dữ liệu nhạy cảm vào production.

Nguồn: Migration guide Fable 5.1

6 Gợi ý chọn model và pilot cho Apero

Loại việc	Bắt đầu bằng	Khi nào nâng cấp
Phân loại, trích xuất, tóm tắt ngắn, routing khối lượng lớn	**Haiku 5.5**	Nếu lỗi chất lượng vượt ngưỡng; tính lại giá với prompt trên 100K.
Code hằng ngày, phân tích dữ liệu, tài liệu và việc có phạm vi rõ	**Sonnet 5.5**	Nếu cần nhiều bước, suy luận dài hoặc phán đoán mở, thử Opus.
Refactor lớn, agent chạy nhiều giờ, hệ thống nhiều phần phụ thuộc	**Opus 5.5**	Chỉ thử Fable nếu Opus ở effort cao chưa đạt và retention phù hợp.
Nghiên cứu nhiều bước, đầu ra hoàn chỉnh trong tác vụ khó	**Fable 5.1**	So với Opus trên bộ tác vụ nội bộ vì giá token cao hơn 2.5 lần.

Nguồn: Gợi ý model theo use case

Pilot nhỏ trước khi chốt ngân sách

- Lấy 30–50 tác vụ thật đã rà soát dữ liệu; chia nhóm dễ, vừa, khó. Đặt tiêu chí đạt, thời gian tối đa và lỗi không chấp nhận được.
- Cố định prompt, tools, effort, output cap, retries và version model. Không trộn benchmark API với leaderboard agent vì harness khác nhau.
- Ghi lại input_tokens, cache_creation_input_tokens, cache_read_input_tokens, output_tokens, thinking_tokens, lượt gọi tool, thời gian và chi phí.
- Chọn model rẻ nhất vẫn đạt ngưỡng chất lượng và SLA; giữ fallback cho tác vụ khó. Đặt spend limit và cảnh báo tại workspace API.

Nguồn: Thinking token usage

Nguồn: Rate limits và monthly spend cap

Kết luận dùng nhanh

Dùng Haiku cho việc lặp; Sonnet làm baseline; Opus khi độ phức tạp thật sự cần thiết; Fable khi bộ đánh giá chứng minh phần giá tăng thêm đáng chi. Benchmark công khai là điểm khởi đầu; chi phí trên workflow Apero mới là quyết định.

Nguồn: Đánh đổi chi phí, model và effort

Nguồn gốc dữ liệu và đường dẫn kiểm tra

Các link dưới đây đi tới trang gốc hoặc đúng phần tài liệu dùng để lập bảng. Giá, model ID, quyền truy cập, benchmark và hạn mức có thể đổi; trước khi ký ngân sách hoặc triển khai, mở lại tài liệu sống và trang limits của workspace.

- Model overview: IDs, context, output và effort hiện hành
- Bảng giá Claude API: input/output, cache, batch, fast mode, region, tools
- Claude Fable 5.1: specs, giá và quyền truy cập
- Claude Opus 5.5: benchmark và giá
- Claude Sonnet 5.5: benchmark và giá
- Claude Haiku 5.5: benchmark và giá theo prompt
- Anthropic: Fable 5.1 và Mythos 5.1
- Rate limits: RPM, ITPM, OTPM, tier, spend cap
- Batch API: mức giảm và nền tảng hỗ trợ
- Fast mode: mức giá và giới hạn
- Prompt caching: breakpoint, TTL và cache hit
- Thinking: token thinking và chi phí output
- Context windows: input/output/thinking
- Model IDs, alias và snapshot
- Data retention của API
- Terminal-Bench 4.0: thay đổi dataset
- Humanity's Last Exam: leaderboard và phương pháp
- Arena Agent leaderboard
- Web search tool: phí tìm kiếm và token kết quả
- Tối ưu chi phí theo task

Ngày đối chiếu: 28/10/2026. Giá dùng USD niêm yết của Claude API do Anthropic trực tiếp cung cấp; hóa đơn nền tảng cloud hoặc hợp đồng riêng có thể khác.