SO SÁNH MỨC TIÊU HAO / CÙNG MỘT GÓI

Cùng một việc, Claude nào tốn quota hơn?

Web · Desktop · CLI — câu trả lời theo từng loại công việc, dựa trên tài liệu chính thức và phép đo công khai.

KẾT LUẬN NGẮN

Anthropic không công bố hệ số kiểu "mỗi lượt trên Desktop tốn gấp X lần Web". Khi cùng một tài khoản, Web, Desktop và Claude Code dùng chung hạn mức của gói. Mức tiêu hao thay đổi chủ yếu theo độ dài ngữ cảnh, model, mức effort, tệp, công cụ và số bước. **[S1] [S2] [S3]**

Vì vậy: một câu hỏi ngắn thường nhẹ ở cả ba nơi; đọc nhiều tài liệu, nghiên cứu bằng công cụ, sửa repo và chạy kiểm thử thường tốn hơn. Chưa có phép đo công khai đủ mạnh để kết luận Web Chat hay Desktop Chat luôn tiết kiệm hơn.

BA GIAO DIỆN · MỘT HẠN MỨC CHUNG

CLAUDE WEB claude.ai	CLAUDE DESKTOP Chat · Cowork · Code	CLAUDE CODE CLI Tương tác · claude -p / SDK
Hỏi đáp, viết, tệp, Research/Web Search	Chat, việc nhiều bước, tệp cục bộ, Code	Làm việc trong terminal; có thể chạy tương tác hoặc tự động

Cần so sánh đúng thứ gì?

Tài liệu này đo mức hao hụt **quota thuê bao**, không phải hóa đơn API. "Cùng một lượng sử dụng" được hiểu là cùng mục tiêu, đầu vào, model, mức effort và công cụ; một công việc thật có thể tạo ra lượng ngữ cảnh và số bước khác nhau giữa các giao diện. Desktop Code và Claude Code trong terminal là luồng lập trình; không nên gộp chúng với Chat trên Desktop hay Web. **[S3] [S10]**

Quy ước mức dùng ở bảng sau: thấp / vừa / cao là đánh giá định tính so với một câu hỏi ngắn, không phải tỷ lệ phần trăm Anthropic cam kết.

01 / SO THEO LOẠI VIỆC

Việc càng nhiều ngữ cảnh và bước, quota càng dễ giảm nhanh

Các mức dưới đây mô tả luồng làm việc phổ biến. Nếu giữ nguyên prompt, model, ngữ cảnh và công cụ thì không có cơ sở để gán một phụ phí cố định cho tên ứng dụng.

LOẠI CÔNG VIỆC	WEB	DESKTOP	CLI	ĐIỀU GÌ LÀM TỐN THÊM?
Hỏi nhanh / sửa một câu	Thấp	Thấp	Thấp	Prompt và lịch sử ngắn; khác biệt giao diện khó tách khỏi khác biệt mô hình.
Trò chuyện dài, hỏi tiếp nhiều lượt	Vừa	Vừa	Vừa	Lịch sử tích lũy và ngữ cảnh dài phải được xử lý lại; bắt đầu phiên mới khi đổi việc.
Tóm tắt tài liệu dài hoặc nhiều tệp	Vừa–cao	Vừa–cao	Vừa–cao	Dung lượng tệp, số tài liệu và yêu cầu phân tích. Chọn giao diện nào không thay thế được việc giảm bớt đầu vào.
Nghiên cứu nhiều nguồn	Cao	Cao nếu dùng Cowork/browser	Vừa–cao nếu có công cụ tìm kiếm	Tìm kiếm, mở nguồn, tổng hợp và kiểm chứng tạo thêm các bước công cụ.
Tạo hoặc sửa tài liệu / bảng tính	Vừa–cao	Cao nếu Cowork thực hiện nhiều bước	Cao nếu dùng Code để tạo file	Tạo file và vòng sửa thường đòi hỏi nhiều lượt hơn một câu trả lời thường.
Hỏi về đoạn mã nhỏ, không có repo	Vừa	Vừa trong Code	Vừa trong Code	Nếu chỉ giải thích đoạn mã thì nhẹ hơn việc cho agent đọc cả dự án.
Sửa repo, chạy test, sửa tiếp	Cao nếu dán nhiều mã	Cao trong Code	Cao trong Code	Đọc file/CLAUDE.md, chạy lệnh, xem lỗi và lặp sửa làm tăng ngữ cảnh và số bước.
Tự động hóa dài, chạy không tương tác	Không tương đương	Cao nếu Cowork làm nhiều bước	Có thể cao; bằng chứng còn hạn chế	Một số phép đo ghi nhận SDK/claude -p dùng quota nhanh hơn CLI tương tác; chưa thể khái quát sang Web/Desktop Chat.

CÁCH ĐỌC BẢNG

Các mức này không phải kết quả benchmark đối đầu giữa ba ứng dụng. Anthropic xác nhận độ dài hội thoại, tệp, model, effort, công cụ và tác vụ nhiều bước ảnh hưởng mức dùng; bảng áp dụng các yếu tố đó vào tình huống điển hình. Mức tự tin cao với yếu tố làm tăng quota, thấp với thứ hạng giữa Web / Desktop / CLI. [S1] [S2] [S4] [S5] [S6]

Một quy tắc thực dụng: câu hỏi ngắn → tài liệu dài / nghiên cứu → tạo file, sửa repo và kiểm thử nhiều bước. Đây là thứ tự theo độ nặng của công việc, không phải bảng xếp hạng ứng dụng.

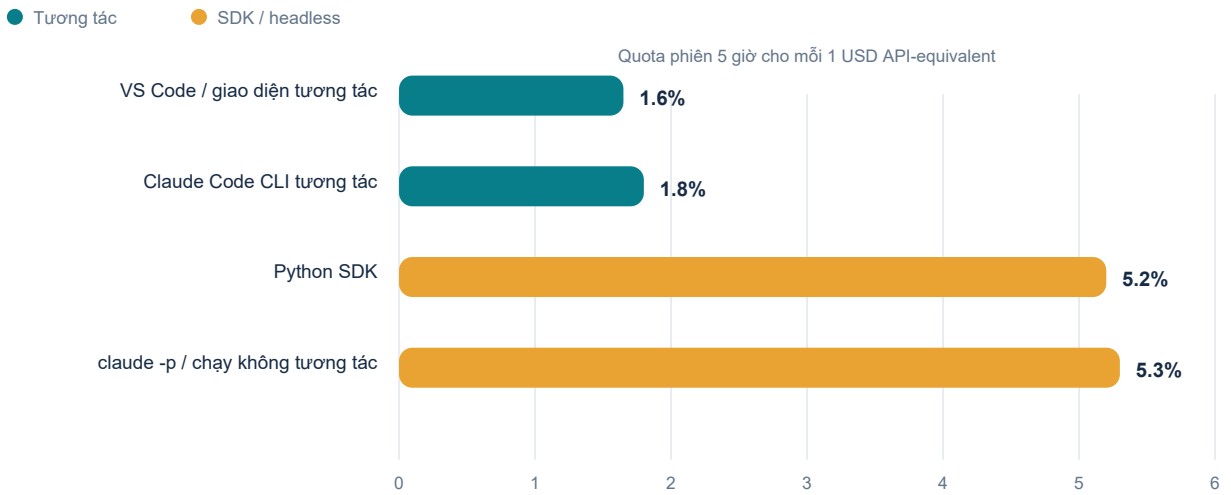
02 / SỐ ĐO ĐÃ CÔNG BỐ

Tín hiệu rõ nhất nằm ở CLI tương tác so với chạy tự động

Hai phép đo cộng đồng gợi ý tác vụ headless/SDK có thể tiêu hao quota nhanh hơn Claude Code tương tác. Chúng chưa trả lời được Web Chat so với Desktop Chat.

PHÉP ĐO 1 · SÁU LẦN CHẠY MỘT TÁC VỤ REFACTOR

Tác giả báo cáo gói Pro, Opus 5 mức effort medium, cùng tác vụ refactor trong repo Python; mỗi lần dùng worktree sạch, khoảng 45–75 lượt gọi model. Mức quota được chuẩn hóa theo 1 USD giá API tương đương, chứ không phải số tiền trả cho gói Pro. [S7]



Trong mẫu này, CLI tương tác khoảng 1,8% hạn mức phiên cho mỗi 1 USD API-equivalent; SDK / claude -p khoảng 5,1–5,5%. Tác giả ước lượng luồng headless dùng hạn mức nhanh hơn gần 3 lần. Bộ đo làm tròn theo phần trăm và tác giả nêu sai số khoảng ±1 điểm phần trăm; vì vậy đừng diễn giải chênh lệch nhỏ giữa hai luồng tương tác như một thứ hạng ổn định. [S7]

PHÉP ĐO 2 · A/B TỪ NGÀY 17/10/2026

Một issue công khai ghi lại thử nghiệm trên gói Team, Claude Code 2.1.300, Opus 5.5 effort high, ba block đo. Tác giả báo cáo luồng `sdk-cli` tiêu thụ hạn mức cửa sổ 5 giờ nhanh hơn khoảng 2,83 lần so với nhãn `claude-vscode` mô phỏng qua Agent SDK. Một phép đo Pro khác trong cùng issue ghi nhận `claude -p` dùng cửa sổ nhanh khoảng 2 lần so với TUI tương tác. Đây là tín hiệu có ích nhưng cỡ mẫu nhỏ, một tài khoản và không phải phép so Web/Desktop/CLI ba bên. [S8] [S9]

KẾT LUẬN CÓ THỂ RÚT RA

Có bằng chứng hạn chế rằng **CLI chạy tự động / SDK** đôi khi ngốn quota nhanh hơn **Claude Code tương tác** trong cùng loại tác vụ. Chưa tìm thấy phép thử công khai, đối đầu trực tiếp và đủ kiểm soát giữa **Web Chat với Desktop Chat**. Không nên kết luận “CLI luôn tốn nhất” hay gán tỷ lệ tiết kiệm cố định cho mỗi ứng dụng.

03 / TỰ ĐO VÀ TRA NGUỒN

Muốn biết tài khoản của bạn tốn ở đâu?

Giao diện Usage chỉ cho biết quota thay đổi; phép thử cần kiểm soát đầu vào để biết nguyên nhân.

01	**Giữ điều kiện giống nhau**	Cùng tài khoản/gói, model và effort. Mỗi lần mở phiên mới; tắt hoặc giữ nguyên tính năng tìm kiếm, connector và công cụ.
02	**Gửi cùng công việc**	Dùng đúng prompt và cùng tệp. Với Code, dùng cùng repo/nhánh sạch và cùng lệnh kiểm thử; không để một giao diện tự đọc thêm cả dự án.
03	**Ghi mức trước và sau**	Chỉ đo một giao diện mỗi lần; chụp phần trăm quota phiên/tuần trước và sau, ghi thời điểm và số lượt công cụ. Lặp lại và đảo thứ tự giao diện.
04	**Tách thuê bao khỏi API**	Nếu Claude Code dùng ANTHROPIC_API_KEY, yêu cầu có thể tính phí API. Kiểm tra /status trước khi so quota gói. Giá API quy đổi chỉ là thước đo token, không phải giá gói.

CÁCH GIẢM HAO PHÍ KHÔNG CẦN THIẾT

Chỉ đính kèm file liên quan, gom các yêu cầu gần nhau, dùng model/effort vừa đủ và bắt đầu phiên mới khi đổi chủ đề. Với phiên Code dài, dùng /compact hoặc /clear khi phù hợp. **[S2] [S4]**

NGUỒN THAM KHẢO · BẤM TÊN ĐỂ MỞ TÀI LIỆU

[S1] How do usage and length limits work? Hạn mức phiên/tuần và các giao diện dùng chung.	**[S2] Usage limit best practices** Độ dài, tệp, công cụ, model và effort làm thay đổi mức dùng.
[S3] Use Claude Code with your Pro or Max plan Đăng nhập Code bằng gói Pro/Max; hạn mức chung; API credits riêng.	**[S4] Models, usage, and limits in Claude Code** Ngữ cảnh Code, model, effort và lệnh quản lý phiên.
[S5] Get started with Claude Cowork Cowork là công việc nhiều bước; mỗi bước dùng token.	**[S6] Create and edit files with Claude** Tạo/sửa file có thể dùng nhiều hơn chat thông thường.
[S7] Community test: interactive vs headless Claude Code Thử nghiệm cộng đồng: sáu lượt, một tác vụ, có hạn chế đo lường.	**[S8] Claude Code quota comparison issue and test notes** Issue ghi lại nhiều phép đo CLI/TUI và giới hạn của chúng.
[S9] Raw report for the 17 Oct 2026 A/B run Báo cáo dữ liệu thô cho phép A/B ngày 17/10/2026.	**[S10] Claude Code user FAQ** Giải thích Claude Code trong Desktop và terminal là luồng Code.

Phạm vi và cách diễn giải

Đối chiếu ngày 28/10/2026. Các nguồn chính thức mô tả hạn mức và yếu tố tiêu hao, nhưng không công bố bảng quy đổi theo giao diện. Hai phép đo headless là báo cáo cộng đồng, số mẫu nhỏ và khác kế hoạch/model; dùng để nêu tín hiệu, không coi là chuẩn chung. Thông tin API-equivalent quy đổi lượng token theo giá API niêm yết, không phải số tiền tiết kiệm được so với phí thuê bao.